

Introduction au Big Data Analytics

Dr. A. SIDIBE

Big Data Analytics ou Analyse des Big Data

Définition

L'analyse des big data ou données massives est le processus souvent complexe d'examen des big data pour découvrir des informations - telles que des modèles cachés, des corrélations, des tendances du marché et des préférences des clients - qui peuvent aider les organisations à prendre des décisions commerciales éclairées.

L'analyse des Big data est une forme d'analyse avancée, qui implique des applications complexes avec des éléments tels que des modèles prédictifs, des algorithmes statistiques et des analyses de simulation alimentées par des systèmes d'analyse.

À grande échelle, les technologies et techniques d'analyse de données offrent aux organisations un moyen d'analyser des ensembles de données et de recueillir de nouvelles informations. Les requêtes de Business Intelligence (BI) répondent à des questions de base sur les opérations et les performances de l'entreprise.

Pourquoi l'Analyse des Big Data est-elle Importante ?

Les organisations ou entreprises peuvent utiliser des systèmes et des logiciels d'analyse de Big Data pour prendre des décisions basées sur les données qui peuvent améliorer les résultats commerciaux. Les avantages peuvent inclure un marketing plus efficace, de nouvelles opportunités de revenus, la personnalisation des clients et une efficacité opérationnelle améliorée. Avec une stratégie efficace, ces avantages peuvent fournir des avantages concurrentiels par rapport aux concurrents.

Les phases du cycle de vie de Big Data Analytics

Les phases du cycle de vie de Big Data Analytics

Passons maintenant en revue le fonctionnement de l'analyse Big Data :

- **Étape 1** - Évaluation de l'analyse de rentabilisation - Le cycle de vie de l'analyse du Big Data commence par une analyse de rentabilisation, qui définit la raison et l'objectif de l'analyse.
- **Étape 2** - Identification des données - Ici, une grande variété de sources de données sont identifiées.
- **Étape 3** - Filtrage des données - Toutes les données identifiées de l'étape précédente sont filtrées ici pour supprimer les données corrompues.
- **Étape 4** - Extraction des données - Les données non compatibles avec l'outil sont extraites puis transformées sous une forme compatible.
- **Étape 5** - Agrégation des données - Dans cette étape, les données avec les mêmes champs dans différents ensembles de données sont intégrées.

Les phases du cycle de vie de Big Data Analytics

- **Étape 6** - Analyse des données - Les données sont évaluées à l'aide d'outils analytiques et statistiques pour découvrir des informations utiles.
- **Étape 7** - Visualisation des données - Avec des outils tels que Tableau, Power BI et QlikView, les analystes Big Data peuvent produire des visualisations graphiques de l'analyse.
- **Étape 8** - Résultat final de l'analyse - Il s'agit de la dernière étape du cycle de vie de l'analyse Big Data, où les résultats finaux de l'analyse sont mis à la disposition des parties prenantes de l'entreprise qui prendront des mesures.

Différents Types de Big Data Analytics

Les quatre types d'analyse Big Data sont les suivants :

- 1. Analyse descriptive**
- 2. Analyse diagnostique**
- 3. Analyse prédictive**
- 4. Analyse prescriptive**

Différents types de Big Data Analytics

Voici les quatre types d'analyse Big Data :

1. Analyse descriptive

L'Analyse descriptive résume les données passées sous une forme que les gens peuvent facilement lire. Cela aide à créer des rapports, comme les revenus, les bénéfices, les ventes d'une entreprise, etc. En outre, cela aide à la tabulation des mesures des médias sociaux.

Cas d'utilisation : The Dow Chemical Company a analysé ses données passées pour augmenter l'utilisation des installations dans ses bureaux et ses laboratoires. À l'aide d'analyses descriptives, Dow a pu identifier l'espace sous-utilisé. Cette consolidation de l'espace a permis à l'entreprise d'économiser près de 4 millions de dollars US par an.

Différents types de Big Data Analytics

2. Analyse diagnostique

L'Analyse diagnostique est fait pour comprendre ce qui a causé un problème en premier lieu. Des techniques telles que l'exploration en profondeur, l'exploration de données et la récupération de données en sont des exemples. Les organisations utilisent l'analyse diagnostique parce qu'elle fournit un aperçu approfondi d'un problème particulier.

Cas d'utilisation : le rapport d'une entreprise de commerce électronique montre que ses ventes ont diminué, bien que les clients ajoutent des produits à leurs paniers. Cela peut être dû à diverses raisons, telles que le formulaire ne s'est pas chargé correctement, les frais d'expédition sont trop élevés ou il n'y a pas suffisamment d'options de paiement disponibles. C'est là que vous pouvez utiliser l'analyse de diagnostic pour trouver la raison.

Différents types de Big Data Analytics

3. Analyse prédictive

L'Analyse prédictive examine les données historiques et actuelles pour faire des prédictions sur l'avenir. L'analyse prédictive utilise l'exploration de données, l'IA et l'apprentissage automatique pour analyser les données actuelles et faire des prédictions sur l'avenir. Il fonctionne sur la prévision des tendances des clients, des tendances du marché, etc.

Cas d'utilisation : PayPal détermine le type de précautions à prendre pour protéger ses clients contre les transactions frauduleuses. À l'aide de l'analyse prédictive, l'entreprise utilise toutes les données historiques de paiement et les données de comportement des utilisateurs et construit un algorithme qui prédit les activités frauduleuses.

Différents types de Big Data Analytics

4. Analyse prescriptive

L'Analyse prescriptive prescrit la solution à un problème particulier. L'analyse de perspective fonctionne à la fois avec l'analyse descriptive et prédictive. La plupart du temps, il s'appuie sur l'IA et l'apprentissage automatique.

Cas d'utilisation : l'analyse prescriptive peut être utilisée pour maximiser les bénéfices d'une compagnie aérienne. Ce type d'analyse est utilisé pour créer un algorithme qui ajustera automatiquement les tarifs des vols en fonction de nombreux facteurs, notamment la demande des clients, la météo, la destination, les périodes de vacances et les prix du pétrole.

Les Technologies et outils clés d'analyse des Big Data

De nombreux types d'outils et de technologies différents sont utilisés pour prendre en charge les processus d'analyse des Big Data. Les technologies et outils courants utilisés pour activer les processus d'analyse des Big Data incluent :

- ❑ **Hadoop, Map Reduce et No SQL** sont les principales technologies Big Data. Ces technologies sont très utiles dans la gestion des Big Data. Des technologies basées sur Hadoop sont appelées **Hadoop Eco system**.
- ❑ **Hadoop**, qui est un framework open source pour le stockage et le traitement de grands ensembles de données. Hadoop peut gérer de grandes quantités de données structurées et non structurées.
- ❑ **Du matériel et des logiciels d'analyse prédictive**, qui traitent de grandes quantités de données complexes et utilisent l'apprentissage automatique (machine learning) et des algorithmes statistiques pour faire des prédictions sur les résultats des événements futurs. Les entreprises utilisent des outils d'analyse prédictive pour la détection des fraudes, le marketing, l'évaluation des risques et les opérations.
- ❑ **Des outils d'analyse de stream data (flux de donnée)**, qui sont utilisés pour filtrer, agréger et analyser les big data qui peuvent être stockées dans de nombreux formats ou plateformes différents.
- ❑ **Stockage de données distribué**, qui est répliqué, généralement sur une base de données non relationnelle. Cela peut être une mesure contre les défaillances de nœuds indépendants, les données volumineuses perdues ou corrompues, ou pour fournir un accès à faible latence.

Les Technologies et outils clés d'analyse des Big Data

- ❑ **Les bases de données NoSQL**, qui sont des systèmes de gestion de données non relationnelles utiles lorsque vous travaillez avec de grands ensembles de données distribuées. Ils ne nécessitent pas de schéma fixe, ce qui les rend idéaux pour les données brutes et non structurées.
- ❑ Un **lac de données (data lake)** est un grand référentiel de stockage (ou entrepôt) qui contient des données brutes au format natif jusqu'à ce qu'elles soient nécessaires.
- ❑ Un **entrepôt de données (data warehouse)**, qui est un référentiel qui stocke de grandes quantités de données collectées par différentes sources. Les entrepôts de données stockent généralement les données à l'aide de schémas prédéfinis.

Les Technologies et outils clés d'analyse des Big Data

- ❑ **Des outils de découverte de connaissances/fouille de données massives (big data mining tools),** qui permettent aux entreprises d'explorer de grandes quantités de données volumineuses structurées et non structurées.
- ❑ **La virtualisation des données, qui permet l'accès aux données sans restrictions techniques.**
- ❑ **Logiciel d'intégration de données,** qui permet de rationaliser le Big Data sur différentes plateformes, notamment Apache, Hadoop, MongoDB et Amazon **EMR**.
- ❑ **Logiciel de qualité des données,** qui nettoie et enrichit les grands ensembles de données.
- ❑ **Logiciel de prétraitement des données,** qui prépare les données pour une analyse ultérieure. Les données sont formatées et les données non structurées sont nettoyées.
- ❑ **Spark,** qui est un framework informatique en cluster open source utilisé pour le traitement de données par lots et par flux

Utilisations et exemples de l'analyse des Big data

- **Acquisition et fidélisation de la clientèle.** Les données sur les consommateurs peuvent aider les efforts de marketing des entreprises, qui peuvent agir sur les tendances pour augmenter la satisfaction des clients. Par exemple, les moteurs de personnalisation pour Amazon, Netflix et Spotify peuvent améliorer l'expérience client et fidéliser la clientèle.
- **Annonces ciblées.** Les données de personnalisation provenant de sources telles que les achats passés, les modèles d'interaction et les historiques de consultation des pages de produits peuvent aider à générer des campagnes publicitaires ciblées et attrayantes pour les utilisateurs au niveau individuel et à plus grande échelle.
- **Développement de produits.** L'analyse des Big data peut fournir des informations pour informer sur la viabilité du produit, les décisions de développement, la mesure des progrès et orienter les améliorations dans la direction de ce qui convient aux clients d'une entreprise.
- **Optimisation des prix.** Les détaillants peuvent opter pour des modèles de tarification qui utilisent et modélisent des données provenant de diverses sources de données afin de maximiser les revenus.
- **Gestion des risques.** L'analyse des Big Data peut identifier de nouveaux risques à partir des modèles de données pour des stratégies de gestion des risques efficaces.
- **Prise de décision améliorée.** Les informations que les utilisateurs métier extraient des données pertinentes peuvent aider les organisations à prendre des décisions plus rapides et plus efficace

Les Avantages de l'Analyse des Big Data

Les avantages de l'utilisation de l'analyse des Big Data incluent :

- Analyser rapidement de grandes quantités de données provenant de différentes sources, dans de nombreux formats et types différents.
- Prendre rapidement des décisions mieux informées pour une stratégie efficace, ce qui peut bénéficier et améliorer la chaîne d'approvisionnement, les opérations et d'autres domaines de prise de décision stratégique.
- Économies de coûts, qui peuvent résulter de nouvelles efficacités et optimisations des processus métier.
- Une meilleure compréhension des besoins, du comportement et des sentiments des clients, ce qui peut conduire à de meilleures informations marketing et fournir des informations pour le développement de produits.
- Des stratégies de gestion des risques améliorées et mieux informées qui s'appuient sur de grands échantillons de données.

Les Défis du Big data Analytics

Malgré les nombreux avantages liés à l'utilisation de l'analyse des Big data, son utilisation présente également des défis :

- **Accessibilité des données.** Avec de plus grandes quantités de données, le stockage et le traitement deviennent plus compliqués. Les Big data doivent être stockées et entretenues correctement pour garantir qu'elles puissent être utilisées par des scientifiques et des analystes de données moins expérimentés.
- **Maintien de la qualité des données.** Avec des volumes élevés de données provenant de diverses sources et dans différents formats, la gestion de la qualité des données pour les Big data nécessite beaucoup de temps, d'efforts et de ressources pour la maintenir correctement.
- **Sécurité des données.** La complexité des systèmes de Big Data présente des défis de sécurité uniques. Répondre correctement aux problèmes de sécurité au sein d'un écosystème de Big Data aussi complexe peut être une entreprise complexe.
- **Choisir les bons outils.** Choisir parmi la vaste gamme d'outils et de plates-formes d'analyse de Big Data disponibles sur le marché peut être déroutant. Les organisations doivent donc savoir comment choisir le meilleur outil qui correspond aux besoins et à l'infrastructure des utilisateurs.
- Avec un manque potentiel de compétences analytiques internes et le coût élevé de l'embauche de data scientists et d'ingénieurs expérimentés, certaines organisations ont du mal à combler les lacunes.