

Le BIG DATA et SES TECHNOLOGIES

Dr. Abdoulaye SIDIBE, Maitre Assistant
Ecole Nationale d'Ingénieurs
Abderhamane Baba Touré (ENI-ABT)

Plan

- 1. Introduction au Big Data**
- 2. C'est Quoi le Big Data**
- 3. Les Caractéristiques du Big Data**
- 4. Les Technologies de Stockage des Big Data**
- 5. Les Technologies de Traitement et d'Analyse des Big Data**
- 6. Les Domaines d'Application du Big Data**
- 7. Les Défis du Big Data**

1.Introduction au Big Data

Le terme Big data a été utilisé pour la première fois pour désigner l'augmentation des volumes de données **au milieu des années 90**.

En 2001, Doug Laney, analyste au cabinet de conseil Meta Group Inc., a élargi la définition du big data. Cette expansion décrit l'augmentation :

- Volume de données stockées et utilisées par les organisations ;
- Variété de données générées par les organisations ; et
- Vélocité, ou vitesse, à laquelle ces données ont été créées et mises à jour

En 2005, ces trois facteurs sont devenus connus sous le nom de 3V du Big Data (Volume, Vélocité et Variété).

En 2006, un autre développement important dans l'histoire du Big Data a été le lancement d'un **projet open source Apache Hadoop pour la gestion et le traitement des Big Data**.

En 2011, l'analyse des Big Data a commencé à s'implanter fermement dans les organisations et le public, avec Hadoop et diverses technologies de mégadonnées connexes.

2. Qu'est-ce que le Big Data ?

Les Big Data décrivent des ensembles de données si volumineux et complexes qu'ils deviennent difficiles à traiter à l'aide de matériel et de logiciels de traitement de données classiques.

Les perspectives du traitement des Big Data sont énormes notamment pour l'analyse d'opinions ou de tendances industrielles, la génomique, l'épidémiologie ou la lutte contre la criminalité.

2.1. L'enjeu du Big Data

L'enjeu du Big Data est **la création de la valeur**.

Il faut exploiter le Big Data pour :

- ❖ Plus de productivité
- ❖ Mieux compétir
- ❖ Autres choses (Nouveau marché, innovation, Partenariat, etc.)

3. Les 5V du Big Data





Figure 1: Les 5V du Big Data

Quelque Exemples de Données Non Structurées

- ❖ Journaux du serveur, du site Web et des applications
- ❖ Données du capteur
- ❖ Images
- ❖ Fichiers
- ❖ Vidéo
- ❖ Fichiers audio
- ❖ E-mail
- ❖ Des médias sociaux



4. Les Technologies Big Data

- ❖ Technologies de **Stockage** Big Data
- ❖ Technologies de **Traitement** et d'**Analyse** Big Data

5. Technologies de Stockage Big Data

Le Stockage de Big Data est assuré par les deux techniques suivantes :

- 1. Systèmes de Fichiers Distribués Hadoop (HDFS)**
- 2. NoSQL**

5.1 Systèmes de Fichiers Distribués Hadoop (HDFS)

HDFS est un système de fichiers conçu pour stocker de fichiers très volumineux avec des modèles d'accès aux données en continu, s'exécutant sur des grappes de matériel de base. Il divise les fichiers volumineux en blocs de 64 Mo par défaut et les stocke dans un grand cluster de manière très efficace. L'architecture HDFS, il existe deux nœuds de base dans un cluster Hadoop

Un nœud de nom (name node) : Il est nœud maître qui contrôle tous les nœuds de données et il contient des métadonnées. Il gère toutes les opérations sur les fichiers comme la lecture, l'écriture, etc.

Un nœud de données (data node) : Les nœuds de données (data node) sont les nœuds esclaves présents dans le cluster Hadoop. Toutes les opérations de fichier effectuées sur ces nœuds et les données sont en fait stockées sur ces nœuds comme décidé par les nœuds de nom.

Le nœud de nom secondaire : Le nœud de nom secondaire est la sauvegarde du nœud de nom.

5.1.2 Architecture HDFS




Figure 2 : Architecture des systèmes de fichiers distribués Hadoop

5.2 NoSQL (Not only SQL)

NoSQL est **un système de gestion de base de données non relationnelle** doté d'un schéma flexible. **Il est utilisé avec des données distribuées**, en particulier **avec des applications impliquant des Big Data** et des applications avec des **données en temps réel** telles que des journaux Web et des applications.

Les bases de données NoSQL prennent en charge différents types de données telles que les **données structurées, semi-structurées et non structurées**.

NoSQL peut être décrit comme une base de données évolutive horizontalement qui convient aux applications avec des magasins de données hiérarchiques.

5.2.1 Les de Base de Données NoSQL Populaires

Base de données Orienté Colonne:

1. Hbase
2. Hypertable
3. Cassandra
4. Accumulo

Base de données Orienté Documents:

1. MongoDB
2. CouchDB
3. Terrastore
4. RavenDB

Bases de données clé-valeur :

1. Riak
2. Infinispan
3. Hazelcast
4. Redis
5. Voldemort

Bases de données basées sur les graphes:

1. Neo4J
2. InfiniteGraph
3. InfoGrid
4. HypergraphDB
5. AllegroGraph

LES MEILLEURES APPLICATIONS POUR CERTAINS TYPES DE VALEURS CLES

(Khasawneh et al, 2020)

RIAK est le meilleur pour la haute disponibilité, la tolérance de partition, la persistance.

REDIS est le meilleur pour les données changeant rapidement, les données statistiques fréquemment écrites, rarement lues.

VOLDEMORT est le meilleur pour les applications avec une grande exigence de capacité de données.

LES MEILLEURES APPLICATIONS POUR CERTAINS TYPES ORIENTÉS SUR COLONNE

HBASE est le meilleur pour l'accès en temps réel, les opérations en bloc (indexation, ..).

CASSANDRA est la meilleure lorsque vous écrivez plus que vous lisez.

ACCUMULO est le meilleur pour l'accès au niveau de la cellule.

LES MEILLEURES APPLICATIONS POUR CERTAINS DOCUMENTS ORIENTÉS

(Khasawneh et al,2020)

MONGODB est le meilleur pour les requêtes dynamiques, la définition d'index, de bonnes performances sur les grosses bases de données.

COUCHDB est idéal pour l'accumulation, les données changeant occasionnellement, les requêtes prédéfinies à exécuter, les cas d'utilisation Web et les applications mobiles

5.3 Technologies de Traitement Big Data

Les plateformes de traitement de Big Data les plus courants sont

1. **Apache Hadoop**
2. **Apache Spark**
3. **Apache Storm**
4. **Apache Flink**

5. 3. 1 Architecture d'Apache Hadoop

L'architecture de Hadoop est composée de trois couches principales:

La première est la couche de stockage de données pour la collecte de données, qui contient Hadoop Distributed File System (HDFS).

La deuxième couche est l'infrastructure YARN, qui assure la gestion des ressources pour la planification des tâches telles que le processeur et la mémoire.

La troisième est **MapReduce**, qui est utilisé pour le traitement données (couche logicielle) avec d'autres processus .




Figure 3 : Architecture de Hadoop
(Gupta et Parveen, 2019)

5.3.2 Ecosystème Apache




Figure 4: Ecosystème Apache

5.3.2 Ecosystème Apache (suite)

❑ Apache Hbase

HBase est une base de données non relationnelle ou orientée colonnes qui s'exécute au-dessus de HDFS (système de fichiers distribué Hadoop). HBase utilise HDFS pour son stockage de données et prend en charge à la fois les calculs par lots utilisant MapReduce et les requêtes ponctuelles. HBase peut traiter des pétaoctets de données.

❑ Apache Hive

Hive est un langage de type SQL appelé HiveQL. De plus, c'est une infrastructure d'entrepôt de données qui fournit toutes ces fonctionnalités. Hive permet d'interroger les données de HDFS et ces requêtes sont converties en tâches de MapReduce.

❑ Apache Sqoop

Sqoop Un outil pour déplacer efficacement les données entre les bases de données relationnelles et HDFS.

5.3.2 Ecosystème Apache (suite)

❑ Apache Flume

Flume est une application basée sur Hadoop qui permet de déplacer des données en flux dans un cluster Hadoop ou HBase.

❑ Apache Pig

Pig est un langage de script utilisé pour écrire des programmes de traitement de grands jeux de données présents dans le cluster Hadoop. **Pig exécute ces programmes et les convertit en tâches de MapReduce**, puis exécute ces tâches.

❑ Apache ZooKeeper

Zookeeper est un outil centralisé qui aide à la synchronisation à travers le cluster Hadoop. **Les services de nommage et la gestion de la configuration sont également fournis par ZooKeeper sur le cluster Hadoop.**

5.3.3 Architecture d'Apache Spark

L'architecture de Spark est composée principalement de 5 couches.

1. La première couche comprend des systèmes de stockage de données tels que HDFS et HBASE.
2. Le gestionnaire des ressources; par exemple, YARN et Mesos.
3. Un **moteur principal Spark**.
4. Une **bibliothèque** composée de SQL, de traitement de données en flux, de MLlib pour l'apprentissage automatique, de Spark R et de GraphX pour le traitement de graphes.
5. Une interface de programme d'application telle que Java ou Scala.




Figure 5 : Architecture de Spark
(Gupta et Parveen, 2019)

5.3.4 Architecture d'Apache Storm

L'architecture de Storm est composée de deux types de nœuds : nœud maître (master node) et le nœud ouvrier (worker node).

Le **nœud maître** est utilisé pour surveiller les défaillances, prendre la responsabilité du nœud distribué et spécifier chaque tâche pour chaque machine. Toutes ces tâches sont collectivement connues sous le nom de Nimbus.

Le **nœud ouvrier** (worker node) est appelé superviseur. Cela fonctionne lorsque Nimbus lui attribue un processus spécifique. Ainsi, chaque sous-processus d'une topologie fonctionne avec de nombreuses machines distribuées. **Zookeeper** joue le rôle de coordinateur entre Nimbus et les superviseurs..




Figure 6 : Architecture de Storm
(Gupta et Parveen, 2019)

5.3.5 Architecture d'Apache Flink

L'architecture de Flink est composée de 5 couches :

1. La couche de stockage peut lire et écrire les données à partir de plusieurs destinations telles que HDFS, des fichiers locaux, etc.
2. La couche de déploiement et de gestion des ressources contient le gestionnaire de cluster pour gérer les tâches de planification, de surveillance des travaux et de gestion des ressources.
3. La couche noyau pour le moteur de traitement en temps réel.
4. La couche d'interface de programmation d'application pour : batch API et streaming API.
5. La couche supérieure est une bibliothèque dans laquelle le programme est écrit en langage de programmation Java ou Scala.




Figure 7 : Architecture de Flink
(Gupta et Parveen, 2019)

6. Quelques Domaines d'Application du Big Data

1) Analyse du comportement des clients

- ❖ L'analyse des journaux Web (web log) des sites de commerce électronique ;
- ❖ L'analyse des journaux d'appel des abonnés par des entreprises de télécommunications;
- ❖ L'analyse des journaux d'achat dans les grands supermarchés

2) Systèmes de recommandation aux clients

3) Secteur de la vente au détail (Retail Sector)

Pour offrir un meilleur service et prédire quel article est le plus demandé, le détaillant utilise les données de facture du client et essaie de prédire des informations utiles pour la veille économique.

4) Ciblage publicitaire

Les sites des réseaux sociaux ciblent l'utilisateur suivant les informations de son profil et ses activités afin de lui montrer des publicités selon ses goûts.

7. Les Défis du Big Data

Les défis de l'analyse des Big Data comprennent:

- ❖ La capture des données
- ❖ Le stockage des données
- ❖ Traitement des données
- ❖ L'analyse des données
- ❖ La confidentialité des informations

Références Bibliographiques

1. Tole, A. A. (2013). Big data challenges. *Database systems journal*, 4(3), 31-40.
2. Nasser, T., & Tariq, R. S. (2015). Big data challenges. *J Comput Eng Inf Technol* 4: 3. doi: [http://dx. doi. org/10.4172/2324.9307\(2\)](http://dx.doi.org/10.4172/2324.9307(2)).
3. Alkatheri, S., Abbas, S., & Siddiqui, M. (2019). A comparative study of big data frameworks. *International Journal of Computer Science and Information Security (IJCSIS)*, 17(1).
4. Alkatheri, S., Abbas, S., & Siddiqui, M. (2019). A comparative study of big data frameworks. *International Journal of Computer Science and Information Security (IJCSIS)*, 17(1).
5. Gupta, H. K., & Parveen, R. (2019, September). Comparative Study of Big Data Frameworks. In *2019 International Conference on Issues and Challenges in Intelligent Computing Techniques (ICICT)* (Vol. 1, pp. 1-4). IEEE.
6. Zomaya, A. Y., & Sakr, S. (Eds.). (2017). Handbook of big data technologies.
7. Wu, D., Sakr, S., & Zhu, L. (2017). Big data storage and data models. In *Handbook of big data technologies* (pp. 3-29). Springer, Cham.
8. Khasawneh, T. N., AL-Sahlee, M. H., & Safia, A. A. (2020, April). SQL, NewSQL, and NOSQL databases: a comparative survey. In *2020 11th International Conference on Information and Communication Systems (ICICS)* (pp. 013-021). IEEE.
9. Kotiyal, B., Kumar, A., Pant, B., & Goudar, R. H. (2013, August). Big data: Mining of log file through Hadoop. In *2013 International Conference on Human Computer Interactions (ICHCI)* (pp. 1-7). IEEE.
10. Singh, J., & Singla, V. (2015). Big data: tools and technologies in big data. *International Journal of Computer Applications*, 112(15).
11. McQueen, B. (2017). Big data analytics for connected vehicles and smart cities. Artech House.

Merci Pour Votre Attention