

Data Mining

Les enjeux

Sommaire

- Introduction aux BDD
- Un Problème et une Solution
- Qu'est –ce que le Data Mining?
- Objectif du Data Mining
- Qu'est-ce qui n'est pas du Data Mining?
- Convergence de trois technologies clés
- Fonctions du Data mining
- Types du Data Mining
- Problèmes

Qu'est-ce qu'une Base de données

Une base de données est une collection organisée de données.



- Mégabases de données qui ne cessent d'augmenter,
- Peu exploiter,
- Alors qu'elles cachent des connaissances décisives face au marché et à la concurrence.

Raisons du développement?

Données:

- Big Data : augmentation sans cesse de données générées
- Twitter : 50M de tweets /jour (=7 téraoctets)
- Facebook : 10 téraoctets /jour
- Youtube : 50h de vid ?éo uploadées /minute
- 2.9 million de mail /seconde

Raisons du développement?

Puissance de calcul

- Augmentation des ordinateurs (loi de Moore)
- Recours à du calcul massivement distribué

7 Raisons du développement?

Création de valeur ajoutée

- Intérêt économique : du produit aux clients.
- Extraire de la connaissance à partir des Big Data

Examples

Collaborateurs

 Search Friends

 Find Friends

 All Friends

 Browse

 Phonebook

 Recently Added

Lists

 Facebook

 Drew

 San Francisco, CA

 family

 best friends

 co-workers

 yoga buddies

 limited profile

 Create

Create New List

Edit List

Delete List



Alexandre Roche
Facebook co-workers



Anikka Fragodt
Facebook co-workers



Ankur Pansari
Facebook co-workers



Aubrey Obata
Facebook co-workers



Cameron Marlow
Facebook co-workers



Leah Pearlman
Facebook co-workers



Meredith Chin
Facebook co-workers

Examples

Informations des Patients

Edit a Patient - Samantha Jones [894567]

Ledger Schedule Lookup View Tx Card Dx/Tx Comment Documents Imaging Print Lette...

Patient | Patient (more) | Status | Relationships | Billing Parties | Insurance | Fees | Appointments | Referrals | History | Custom

First/Last Name:

Sort Name:

Greeting: Gender:

Street:

City:

State: Zip:

Birthdate: 14 years

Phone #s:

Type	Number	Note
Home	(818) 693-0369	

SSN / Gov't ID #:

E-mail:

Mail Method:

Alerts:

Date	Alert
N/A	Requires Penicillin before ...
N/A	Allergic to Latex

Patient ID:

Balance Summary - All Billing Parties:

	Patient	Insurance	Total
Current w/o Credits	\$200.00	\$0.00	\$200.00
Credits	\$0.00	\$0.00	\$0.00
Current w/ Credits	\$200.00	\$0.00	\$200.00
Over 30	\$0.00	\$0.00	\$0.00
Over 60	\$0.00	\$0.00	\$0.00
Over 90	\$200.00	\$0.00	\$200.00
Total Due	\$400.00	\$0.00	\$400.00
Total Past Due	\$200.00	\$0.00	\$200.00
Unbilled Balance	\$400.00	\$0.00	\$400.00



Exemples

Système de Réservation de vol

TASAR - PRODUCTION

File Edit Booking Inventory Queues Accounting Tools DCS Maintenance Window Help



Availability

Origin: FLL ... FT LAUDERDALE/HOLLYWOOD INTL, FORT LAUDE

Destination: LGA ... LA GUARDIA INTERNATIONAL, NEW YORK

Number of Passengers
Adults: 1 Children: 0 Infants: 0

Booking Type

☒ Roundtrip

☐ One-Way

☐ Other

Show

☒ Available Only

☐ All Flights

Departure Date: 19Nov03

Duration of Stay: Days

Return Date: 19Nov03

☐ Non Revenue

☐ Roundtrip Fares

No	Flight	Dep.	Arr.	Date	Time
1	* NK604	FLL	LGA	Wed, 19Nov2003	07:10
	C 263.00 A 198.00 Y 223.00 B 198.00 H 173.00 Q 148.00 M				
2	* NK1758	FLL	LGA	Wed, 19Nov2003	09:00
	C 263.00 A 198.00 Y 223.00 B 198.00 H 173.00 Q 148.00 M				
3	* NK770	FLL	LGA	Wed, 19Nov2003	11:00
	C 263.00 A 198.00 Y 223.00 B 198.00 H 173.00 Q 148.00 M				
4	* NK196	FLL	LGA	Wed, 19Nov2003	15:20
	C 263.00 A 198.00 Y 223.00 B 198.00 H 173.00 Q 148.00 M				
5	* NK1582	FLL	LGA	Wed, 19Nov2003	17:50
	C 263.00 A 198.00 Y 223.00 B 198.00 H 173.00 Q 148.00 M				

No	Flight	Dep.	Arr.	Date	Time
1	* NK705	LGA	FLL	Wed, 19Nov2003	06:50
	C 263.00 A 198.00 Y 223.00 B 198.00 H 173.00 Q 148.00 M				
2	* NK1581	LGA	FLL	Wed, 19Nov2003	07:00
	C 263.00 A 198.00 Y 223.00 B 198.00 H 173.00 Q 148.00 M				
3	* NK1123	LGA	FLL	Wed, 19Nov2003	09:30
	C 263.00 A 198.00 Y 223.00 B 198.00 H 173.00 Q 148.00 M				
4	* NK197	LGA	FLL	Wed, 19Nov2003	12:30
	C 263.00 A 198.00 Y 223.00 B 198.00 H 173.00 Q 148.00 M				
5	* NK751	LGA	FLL	Wed, 19Nov2003	15:15

Quote...

Fares...

Details...

Print

Passenger Manifest

Filter

Flight number: NK709

Flight date: 3

NK709



Passenger Name	Locator	Cat.
AMBROSE/DANIEL	HLCJ2T	S
BAGHDASARIAN/NERSIS	HLKCJZ	S
BARARSANI/NIMA	HKGFXV	S
BECK/DAVID	HKKFQP	S
BERBERIAN/ARA	HKZNHQ	S
BLACK/JESSERAY	HKZFTV	S
BLACK/THOMASCOLBY	HKZFTV	S
CAMERO/LOUIS	HKWXXJ	S
CHEN/LI	HKLMTM	S
CZEWSKI/RACHEL A	HLJNBP	S

Rows: 87

Print

Clear

Search

Close

AboutTASAR

TASAR

Version 1.0.234

Copyright (c) 2003 RRT Ltd

The World's First Airline Reservation System based on a three-tiered network design concept

This product is licensed to:

Spirit Airlines

Visit our web site at: www.RRTechnologies.net

Login information

User: PETER

City: FLL

Company: NK

Branch: 0001

Groups

Administrators

OK

PRODUCTION

11/19/2003

4:26 PM

Donnée vs. information

- Qu'est-ce qu'une donnée?
 - Une donnée est une information non traitée.




- Qu'est-ce qu'une **information**?
 - Une Information est une donnée organisée et communiquée de telle façon qu'elle a un sens.
 - La **donnée** est transformée en **information**, et l'information est transformée en **connaissance**.
 - Connaissance, information évaluée et organisée de telle sorte qu'elle peut être utilisée délibérément.

Pourquoi on a besoin d'une BDD?

- Garder les enregistrements de nos:
 - Clients
 - Staff
 - Volontaires
- Garder les enregistrements de nos activités et nos interventions
- Garder les ventes
- Développer les rapports
- Améliorer la recherche

La mission d'un SGBD

Est de transformer



BDD et SGBD

- **Base de données (BDD):** Collection partagée de données logiquement liées (avec une description de ces données), conçue pour atteindre les besoins en information d'une organisation.
- **Système de Gestion de Bases de Données (SGBD):** Un système informatique permettant aux utilisateurs de définir, créer et maintenir la base de données tout en assurant le contrôle d'accès à cette base de données.

Qui et Comment ?

- C'est le SGBD qui fait ce travail.
- En utilisant des logiciels (programmes) informatiques:
Access, FileMaker, Lotus Notes, Oracle or SQL Server,
- Ces logiciels contiennent des outils pour ajouter, modifier ou supprimer des données de la BDD, poser des questions (requêtes) à propos des données stockées dans la BDD et produire des rapports et des résumés de certaines données de la BDD.

Allons maintenant au Data Mining !

- **c'est quoi le data Mining.**

Un Problème ...

- Vous êtes Responsable du Marketing dans une société de courtage
 - Problème: **Renoncement** très élevé des clients
 - > Taux de renoncement 40%
(La période de six mois de courtage est finie)
 - Les clients reçoivent des **encouragements** lorsque l'affaire est ouverte
 - Donner de nouveaux encouragements à chaque client est très coûteux (parfois inutile)
 - Ramener un client après son départ est à la fois difficile et coûteux

Une Solution ...


- Un mois avant l'expiration de la période de courtage, **prévoir** (prédire) les clients qui vont quitter (renoncer)
- Si on veut garder un client prévu au renoncement, on lui **offre** quelque chose en se basant sur sa **valeur prédite**
 - > Les autres clients non prévus au renoncement n'auront besoin de rien
- Si on ne veut pas garder un client prévu au renoncement, on ne le laisse partir
- Comment prévoir un futur comportement?
 - > Les Cartes?
 - > Les boules magiques?
 - > Autres choses?



Processus du KDD

- **Découverte des Connaissances dans les Bases de Données ou Knowledge Discovery in Databases (KDD)** est un processus multi-étapes pour la découverte d'informations utiles et de patterns à partir des données
- **Fouille de Données ou Data Mining** est l'utilisation d'algorithmes pour l'extraction d'informations et de patterns, conduite par le processus du KDD.
- Plusieurs documents considèrent le KDD et le Data Mining comme étant un même processus, mais il est également possible de traiter le Data Mining en tant qu'étape de découverte du processus de KDD.

Etapes du processus KDD



Etapes du processus KDD

1. Sélection-

Extraction de données –Obtenir les données à partir des sources de données hétérogènes –Bases de données, Data warehouses ou Entrepôts de données, World wide web ou autres récipients de données.

2. Prétraitement-

Nettoyage des données- Incomplètes , incohérentes inconsistantes données à nettoyer – données absentes peuvent être ignorées ou prédites, données erronées à supprimer ou à corriger.

3. Transformation-

Intégration des données- Combiner les données issues des différentes sources dans une forme cohérente – Codage des Données sous des formats communs, normalisation, réduction.

Etapes du processus KDD

4. Data mining –

Application d'algorithmes sur les données transformées pour l'extraction d'informations et de patterns

5. Interprétation/évaluation des patterns

Evaluation des patterns- Evaluer l'intérêt des patterns trouvés ou appliquer des mesures d'interressement pour les filtrer.

Présentation des informations/connaissances découvertes- Les techniques de visualisation peuvent être utilisées.

Qu'est-ce que le Data Mining?

Quelques Définitions

- “L'**extraction** **non triviale**, à partir des **données**, d'**informations** implicites, inconnues apriori et potentiellement **utiles**” (Piatetsky-Shapiro)
- “...L'**extraction** **automatique** ou adéquate de **patterns** **représentant** des **connaissances** implicitement stockées ou capturées dans des **bases de données** volumineuses, des entrepôts de données, du Web, ... ou des flôts de données.” (Han, pg xxi)
- “...Le processus de **découverte** de **patterns** à partir des **données**. Le processus doit être **automatique** ou (généralement) semi-automatique. Les patterns découverts doivent être **significatifs**...” (Witten, pg 5)
- “...**trouver** l'**information** cachée dans les **bases de données**.” (Dunham, pg 3)

Pourquoi le Data Mining?

- On dit souvent que le Data Mining est ...compliqué. Pourquoi donc doit-on l'apprendre?
- Pourquoi ne pas utiliser seulement les bases de données relationnelles? Que veut-on obtenir de plus en suivant ces étapes [extra-compliquées]?
- Ce processus n'est-t-il pas coûteux? Il semble qu'il a besoin de beaucoup de talent, de programmation, de temps de calcul et d'espace de stockage.
- Où est-il le profit?
- Data Mining n'est pas seulement un exercice académique malin, il a des applications réelles très profitables. Pratiquement toutes les grandes compagnies et plusieurs gouvernements développent le data mining comme une tâche de leur planification et analyse.

Objectif du Data Mining

- **Simplification et automatisation de l'ensemble du processus statistique, allant de la/les source(s) de données jusqu'au modèle de l'application**
- **Evolution au cours des années**
 - > **Le Statistician remplace les données par le modèle**
 - > **Différents algorithmes/outils de data mining sont disponibles**
 - > **L'expertise statistique est exigée pour développer des logiciels intelligents**

Data Mining c'est ...




- Arbres de décision




- Classification par Voisinage



- Réseaux de neurones



- Règles d'association



- Clustering

Qu'est-ce qui n'est pas du Data Mining?

Ce n'est pas du Data Mining

- Chercher un numéro de téléphone dans un annuaire
- Requête d'un moteur de recherche internet à propos d'informations sur "Amazon"

C'est du Data Mining

- Certains noms sont populaires dans certaines régions de Mumbai (Kulkarni, Shah, Iyer...)
- Grouper les documents similaires retournés par un moteur de recherche selon leur contexte (e.g. Amazon rainforest, Amazon.com,)

Traitement BDD VS Data Mining

- Requête
 - Bien définie
 - SQL

Données

- Données
Opérationnelles

Sortie

- Précise
- Un sous-ensemble de la base de données

- Requête
 - Mal définie
 - Aucun langage de requête précis


Données

- Données non
opérationnelles

Sortie

- Probable
- Ce n'est pas un sous-ensemble de la base de données

Convergence de 3 Technologies clés



1. Augmentation de la puissance de calcul

- Loi de Moore: **la puissance de calcul double** chaque 18 mois
- **Stations de travail puissantes**: de plus en plus fréquentes
- Serveurs rentables fournissent un **traitement parallèle** au marché grand public

1. Explosion des données

- Le taux de création des **données** est en **accélération** chaque année. En 2003, UC Berkeley a estimé que l'année précédente (2002) a généré **5 exaoctets** de données, dont 92% sont stockée sur des média électroniques.
- **Mega < Giga < Tera < Peta < Exa ...** Toutes les **données** des **livres** de la bibliothèque du Congrès américain sont. **~136 Teraoctets**
- VLBI Telescopes produit **16 Gigaoctets** de données chaque seconde.
- Google effectue sa recherche dans **18 billions+** de **pages web**.

1. Implications de l'explosion des données

- Lorsque le volume des **données augmente**, la proportion d'**information décroît**.
- Comme les données sont de plus en plus générées automatiquement, on a besoin de solutions automatiques pour transformer ces données brutes en information.
- Les compagnies ont besoin de tirer profit des leurs données stockées ... Sinon, pourquoi doivent-elles les stocker?

2. Amélioration de la collecte et la gestion des données



- Collecte des données? Accès ? Navigation ? Mining
- Plus on a les données plus c'est bon! (généralement)

3. Algorithmes de statistiques et d'apprentissage

- Les techniques ont souvent attendu les technologies de calcul pour les saisir**
- Les Statisticiens réalisaient manuellement les tâches de data mining**
- Un bon algorithme d'apprentissage automatique (machine learning) est une application intelligente des processus statistiques**
- La recherche en data mining s'intéresse à l'ajustement des techniques existantes pour réaliser un pourcentage modeste de gains**


3.Donnée/Information/Connaissance/Sagesse

- **Par exemple**, l'application du data mining peut nous dire qu'il y a une **corrélation** entre **l'achat** des **magasines de musique et du café**, mais ne peut pas nous dire comment exploiter cette connaissance. Devons-nous les arranger l'un à côté de l'autre pour renforcer la tendance, ou les arranger n'importe où, les gens vont les acheter ensemble peu importe leur endroit de stockage.
- Le Data mining peut aider les gestionnaires à l'élaboration de stratégies pour leur entreprises mais ne peut pas leur donner les stratégies.

Fonctions de Data mining

- Toutes les fonctions de Data Mining peuvent être considérées comme une tentative de trouver un modèle pour ajuster les données.
- Chaque fonction a besoin de critères pour créer un modèle plutôt qu'un autre.
- Chaque fonction a besoin d'une technique pour comparer les données.
- Deux types de modèles:
 - **Les modèles prédictives:** Prédire une valeur inconnue sur la base de données connues
 - **Les modèles descriptives:** Identifier les patterns des données

Fonctions de Data mining



Types des problèmes de Data Mining

- **Database**

- Trouver tous les demandeurs de crédits ayant le nom “Mehenni”
- Identifier les clients ayant acheté plus de 10,000 DA le mois précédent
- Trouver tous les clients ayant acheté du lait

- **Data Mining**

- Trouver tous les demandeurs de crédit qui ont un risque de crédit mineur. (classification)
- Identifier les clients qui ont des habitudes d'achat similaires. (Clustering)
- Trouver tous les items qui sont fréquemment achetés avec le lait (règles d'association)

Types de problèmes de Data Mining

- Classification
- Clustering
- Règles d'association



Domaines d'applications (1)

Entreprise et Relation Clients : système de création de profils clients,

- Ciblage de clients potentiels et nouveaux marchés
- Finances : minimisation de risques financiers

Domaines d'applications (2)

- *Bioinformatique* : Analyse du génome, mise au point de médicaments,...
- *Internet* : spam, e-commerce, détection d'intrusion, recherche d'informations etc...
- *Sécurité*

Domaines d'applications (3)

Activités scientifiques diagnostic
médical, santé publique : ex, étude
du génome analyse chimique,
biologique et pharmaceutique
exploitation de données
astronomiques

Exemples d'applications: E-Commerce (1)

Dell:

- Stocker les séquences de clicks des visiteurs, analyser les caractéristiques des acheteurs
- Faire du "targeting" lors de la visite d'un client potentiel
- Adapter le contenu du site pour maximiser la probabilité d'un achat

Exemples d'applications: E-Commerce (2)

Amazon

Opportunité : la liste des achats des clients est stockée en mémoire ; les clients notent les produits ! Comment tirer profit de ces données pour proposer des produits à un autre client ?

Solutions : technique dit de filtrage collaboratif permettant de regrouper des clients ayant les mêmes “goûts”.

Exemples d'Applications: Analyse des Risques (1)

Détection de fraudes pour les assurances

- Analyse des déclarations des assurés par un expert afin d'identifier les cas de fraudes.
- Applications de méthodes statistiques pour identifier les déclarations fortement corrélées à la fraude.

Exemples d'Applications: Analyse des Risques (2)

Prêt Bancaire

- Objectif des banques : réduire le risque des prêts bancaires.
- Créer un modèle à partir de caractéristiques des clients pour discriminer les clients à risque des autres.

Exemple d'Applications: Commerce (1)

Organisation de rayonnage

Objectifs : Identifier les produits que les gens sont susceptibles d'acheter conjointement afin d'organiser les rayonnages

Anecdote : une étude a montré que la vente de bière et des chips est plus importante si le rayon des couches n'est pas trop loin.

Exemple d'Applications: Commerce (2)

Opinion mining

Exemple : analyser l'opinion des usagers sur les produits d'une entreprise à travers les commentaires sur les réseaux sociaux et les blogs.

Exemple d'Applications: Médicale

- Médecine et pharmacie:
 - ❖ Diagnostic : découvrir d'après les symptômes du patient sa maladie
 - ❖ Choix du médicament le plus approprié pour guérir une maladie donnée

Liens entre DM et d'autres disciplines

