

Introduction aux Entrepôts de Données ou Data Warehouse

Dr A. SIDIBE

Objectifs

- ❖ Connaître les principaux domaines d'application des data warehouses
- ❖ Connaître le paradigme du décisionnel (et son articulation avec le paradigme transactionnel)
- ❖ **Connaître les principes, les étapes et les méthodes de la modélisation dimensionnelle**
- ❖ Savoir faire **une étude de besoins**
- ❖ Savoir faire une **étude des données existantes**
- ❖ Savoir faire un **modèle dimensionnel en étoile**
- ❖ Savoir **implémenter un data warehouse** avec **un SGBD relationnel**
- ❖ Savoir **implémenter un processus ETL** vers un data warehouse
- ❖ Savoir **interroger en SQL un data warehouse** en vue d'applications décisionnelles
- ❖ Savoir **faire un modèle dimensionnel en étoile** et **en flocon**
- ❖ Savoir implémenter un **data mart**

Le décisionnel

Définition

Le **système d'information décisionnel** est un ensemble de données organisées de façon spécifiques, facilement accessibles et appropriées à la prise de décision. **La finalité d'un système décisionnel est le pilotage d'entreprise. Les systèmes de gestion sont dédiés aux métiers de l'entreprise. Les systèmes décisionnels sont dédiés au management de l'entreprise.**

Synonymes :

informatique décisionnelle, business intelligence, BI

Le décisionnel ?

Les systèmes de gestion sont dédiés **aux métiers (vue verticale)**; tandis que les systèmes décisionnels sont **dédiés au pilotage de l'entreprise (vue transversale)** ;

Passage des données de production aux données décisionnelles

Les bases de production : toutes les sources de données (légales, juridiques, fiscales, politiques, techniques, marketing...)

Comment organiser ces différentes données dans un ensemble cohérent afin de procéder à toutes les analyses nécessaires pour construire **les indicateurs indispensables au pilotage de l'entreprise ?**

Par un processus d'entreposage de données (Data Warehousing)

2. Enjeux du décisionnel

La prise de décisions stratégiques dans une **organisation** nécessite le recours et le croisement de multiples informations qui concernent tous les départements : production, RH, DAF, achats, ventes, marketing, service après-vente, maintenance, R&D... Or ces données sont généralement :

- éparpillées au sein des départements et non connectées entre elles;
- hétérogènes dans leurs formats techniques et leurs organisations structurelles, voire leurs sémantiques;
- implémentées pour l'action (par construction) et non pour l'analyse;
- volatiles, au sens où leur mise à jour peut conduire à oublier des informations obsolètes ;

2. Enjeux du décisionnel

Exemple

Un catalogue de produits sera conçu pour permettre de trouver facilement un produit en fonction de caractéristiques précises, de faire des mises à jour rapides et fiables, de gérer des stocks...

Mais un système décisionnel souhaitera :

- connaître l'organisation des produits selon certaines caractéristiques et regroupements qui ne sont pas forcément premiers dans la gestion quotidienne ;
- croiser le catalogue avec les ventes..

Fondamental

L'enjeu des systèmes décisionnels est de donner accès aux données existantes dans l'organisation, sous une forme intégrée, afin de faciliter leur interrogation croisée et massive.

3. Exploitation des données

Les données agrégées dans un système décisionnel servent à trois grandes catégories d'usage :

- **La production de rapport récurrents** (reporting)
- **L'exploration manuelle**
- **L'analyse de données** (descriptive ou prédictive)

Reporting

Le principe du **reporting** est **d'agrég**er et de **synthétiser** des données nombreuses et complexes sous forme **d'indicateurs, de tableaux, de graphiques** permettant d'en avoir une **appréhension globale et simplifiée**.

Le **reporting** s'appuie principalement sur les agrégats (GROUP BY en SQL par exemple) afin de faire apparaître des **comptages, sommes** ou **moyennes** en fonction de **critères d'analyses**.

Le **reporting** est généralement récurrent, le même rapport sera produit à intervalles réguliers pour contrôler les variations des indicateurs.

Les outils de **reporting** proposent la réalisation de rapports selon un format prédéterminé. Les bases de données sont interrogées selon les requêtes SQL préparées lors de l'élaboration du modèle. Le rapport peut ensuite être diffusé sur l'Intranet, périodiquement en automatique ou ponctuellement à la demande.

L'outil d'élaboration du modèle du rapport offre des fonctions spécifiques de calcul et de présentation (graphiques) afin de concevoir des comptes rendus adaptés et pertinents.

3. Exploitation des données

Les outils de reporting proposent **la réalisation de rapports selon un format prédéterminé**. Les bases de données sont interrogées selon les requêtes SQL préparées lors de l'élaboration du modèle. Le rapport peut ensuite être diffusé sur l'Intranet, périodiquement en automatique ou ponctuellement à la demande.

L'outil d'élaboration du modèle du rapport offre des fonctions spécifiques de calcul et de présentation (graphiques) afin de concevoir des comptes rendus adaptés et pertinents.

3. Exploitation des données

Définition : Tableaux de bord

Un **tableau de bord** est un instrument de mesure de la performance facilitant le pilotage "proactif" d'une ou plusieurs activités dans le cadre d'une démarche de progrès. Le tableau de bord contribue à réduire l'incertitude et facilite la prise de risque inhérente à toutes décisions. C'est un instrument d'aide à la décision qui dynamise la réflexion et facilite la communication

3. Exploitation des données

Définition : Exploration manuelle

Une autre exploitation de données en contexte décisionnel consiste à pouvoir explorer les données de façon peu dirigée (heuristique) afin de trouver des réponses à des questions que l'on ne s'est pas posées (sérendipité). L'idée générale est plutôt que les réponses aux premières questions que l'on se pose conduiront à se poser de nouvelles questions.

L'exploration de données s'appuie sur des outils permettant de manipulation (IHM) et de visualiser (infovis) les données selon des requêtes dynamiquement produites par des utilisateurs experts du domaine.

3. Exploitation des données

Définition : Analyse de données

L'analyse de données est une branche de la statistique qui permet de mettre en évidence **des tendances des données** ou 2 non évidentes a priori.

- Dans le cas de **l'analyse descriptive**, Il s'agit de rechercher une information statistique "cachée" que l'on ne connaît pas a priori.
- **L'approche prédictive** consiste à réaliser un modèle statistique des corrélations entre les données à partir d'échantillons d'apprentissage, puis à appliquer le modèle à des données nouvelles pour prédire leur comportement, avec des raisonnements du type "si ... alors" ; ou pour classifier des données (tel objet caractérisé par telles données appartient-il à telle classe ?). Les résultats sont généralement qualifiés par une probabilité d'occurrence.

4. Éthique et limites des systèmes décisionnels

4.1 Rationalisation excessive et processus complexes

Les systèmes décisionnels produisent des indicateurs ou s'appuient sur des modèles dont l'objectif est de simplifier la réalité pour aider à la prise de décision.

Mais la décision doit bien réintégrer des évaluations humaines qui la replacent dans sa réalité, qui est restée complexe.

- **Le modèle** ou **l'indicateur** n'est pas la réalité, s'en est une représentation.
- **La décision** ne s'applique pas à une représentation, mais à la réalité.

4. Éthique et limites des systèmes décisionnels

4. 2 Sélectivité des données et organisations humaines

Les systèmes décisionnels s'appuient sur les données que l'on est en mesure de produire, mais ces données ne peuvent pas intégrer toutes les dimensions d'une organisation et de son environnement, en particulier les dimensions humaines. Or ces dimensions cachées au système décisionnel déterminent de nombreux fonctionnements de l'organisation, et doivent continuer d'être prises en compte.

4. Éthique et limites des systèmes décisionnels

4.3 L'interprétation est humaine

Un système informatique produit des indicateurs qui nécessitent des interprétations humaines, expertes dans le cas du décisionnel. Un système informatique ne produit pas des directives qu'une organisation humaine doit suivre !

4.4 L'erreur est informatique

Les résultats produits par les systèmes décisionnels sont le résultat de conceptions informatiques et mathématiques complexes, qui peuvent receler des erreurs ou des raccourcis, par ailleurs les résultats sont souvent statistiques, donc non déterministes. La possibilité d'une erreur ou d'une approximation inadaptée devra toujours être prise en compte dans les décisions.

5. Architecture d'un système décisionnel

Tout système décisionnel est architecturé globalement de la même façon :

- En amont un accès au système transactionnel en lecture seule
- Un DW fusionnant les données requises
- Un ETL permettant d'alimenter le DW à partir des données existantes
- Des applications d'exploitation de reporting, exploration et/ou prédiction
- D'éventuels DM permettant de simplifier le DW en vue de certaines applications

Fondamental : Principe de fonctionnement

Le but du système est globalement d'être capable de présenter des tableaux de données (fichiers plats) en intrants des applications d'exploitation.

6. Conception d'un système décisionnel

Un projet de système décisionnel se structure selon quatre grands axes :

1. Étude des besoins et de l'existant

- Étude des besoins utilisateurs
- Étude des données existantes

2. Modélisation et conception

- Modélisation dimensionnelle
- Architecture technique
- Spécification des outils d'exploitation


3. Implémentation du data warehouse

- Implémentation du DW et des DM
- Mise en place de l'ETL

4. Implémentation des outils d'exploitation

- Implémentation des outils de reporting
- Implémentation des outils d'exploration
- Implémentation des outils de prédiction

6. Conception d'un système décisionnel



Lifecycle approach to DW/BI (Kimball, 2008, p3)

7. Quelques exemples d'application

- **Analyse du comportement de consommateurs** ou de citoyens, en fonction de leurs caractéristiques (sexe, age...), de critères socio-économiques (profession...), géographiques...
- **Analyse de ventes en fonction de l'implantation géographique de magasins** (densité, caractéristiques des régions...), de l'organisation de magasins (rayonnage, marketing, RH...)
- **Analyse des structures de paniers** (quel produit est vendu en même temps que quel autre à quelles conditions ?)
- **Prédiction de ventes en fonctions de données conjoncturelles, gestion des stocks, des approvisionnements**
- **Contrôle qualité et analyse de défaut des chaînes de production** en fonction des centres de production, des organisations, des fournisseurs...

Motivations

Contexte

- ❖ **Besoin:** prise de décisions stratégiques et tactiques
- ❖ **Pourquoi:** besoin de réactivité
- ❖ **Qui:** les décideurs (non informaticiens)

Explosion des données

- ❖ Masse importante de données
- ❖ Inexploitables par les méthodes d'analyse classiques
- ❖ Besoin de traitement en temps réel de ces données

Les données utilisables par les décideurs

□ Données opérationnelles (de production)

- ❖ Bases de données (Oracle, SQL Server, MySQL ...)
- ❖ Fichiers plats, XML,

□ Caractéristiques de ces données:

- ❖ Distribuées: systèmes éparpillés
- ❖ Hétérogènes: systèmes et structures de données différents
- ❖ Volatiles: pas d'historisation systématique

Pourquoi utiliser un entrepôt de données ?

Les entrepôts de données sont une bonne option lorsque vous devez **stocker de grandes quantités de données historiques** et/ou **effectuer une analyse approfondie de vos données pour générer de la business intelligence**. En raison de leur nature **hautement structurée**, l'analyse des données dans les entrepôts de données est relativement simple et peut être effectuée **par des analystes métiers** et **des data scientists**.

Notez que les entrepôts de données ne sont pas destinés à satisfaire les besoins de transaction et de concurrence d'une application. Si une organisation détermine qu'elle bénéficiera d'un entrepôt de données, elle aura besoin d'une ou plusieurs bases de données distinctes pour alimenter ses opérations quotidiennes.


Problématique

❑ Comment répondre aux demandes des décideurs?

- En donnant un accès rapide et simple à l'information stratégique;
- En donnant du sens aux données.

Mettre en place un système d'information dédié aux applications décisionnelles: **Le Datawarehouse**

Naissance du Datawarehouse



Exemple de Datawarehouse




Figure : Exemple de Framework typique d'un entrepôt de données

Qu'est-ce qu'un entrepôt de données ou data warehouse?

- ❑ Un **entrepôt de données ou data warehouse** «est une collection de données orientées **sujets**, intégrées, **non volatiles**, **historisées et organisées** pour le support du **processus d'aide à la décision** » selon **Bill Inmon**
- ❑ Un **entrepôt de données ou data warehouse** est une base de données dans laquelle sont **déposées** après **nettoyage** et **homogénéisation** les informations en provenance **des différents systèmes de production de l'entreprise OLTP** (Online Transaction Processing)
- ❑ Un **entrepôt de données ou data warehouse** est un système qui stocke des informations hautement structurées provenant de diverses sources. Les entrepôts de données stockent généralement les données actuelles et historiques d'un ou plusieurs systèmes.
- ❑ **Data warehousing** est Le processus qui permet de construire un data warehouse

Qu'est-ce qu'un entrepôt de données ou data warehouse?

L'objectif de l'utilisation d'un entrepôt de données est de combiner des sources de données disparates afin d'analyser les données, de rechercher des informations et de créer de la business intelligence (BI) sous forme de rapports et de tableaux de bord.

On peut se demander peut-être : « Un entrepôt de données est-il une base de données ? Oui, un entrepôt de données est une base de données géante optimisée pour l'analyse.

Caractéristiques des données d'un DW

Bill Inmon a proposé les termes de : Entreprise Data warehouse (EDW) ou Corporate Information Factory (CIF)

- ✓ Le DWH est **orienté sujets** : les données collectées doivent être orientées “métier” et donc triées par thème
- ✓ Le DWH est composé de **données intégrées** : un “nettoyage” préalable des données est nécessaire dans un souci de rationalisation et de normalisation
- ✓ Les données du DWH sont **non volatiles** : une donnée entrée dans l'entrepôt n'a pas vocation à être supprimée ;
- ✓ Les données du DWH doivent être **historisées**, donc datées

Caractéristiques des données d'un DW

❑ Orientées sujet

- **Organisées autour de sujets ou thèmes majeurs** de l'entreprise bien précis, ex: **client**, **produit**, **ventes**.
- **S'intéresse à la modélisation et l'analyse des données pour aider les décideurs**, non pas pour des activités quotidiennes ou traitement transactionnel.
- Fournit une vue **simple** et **concise** concernant un sujet particulier en **excluant les données** qui ne servent pas à la prise de décision

Caractéristiques des données d'un DW

❑ Evolutif dans le temps

- La portée temporelle des données dans un data warehouse est plus longue que celle des bases opérationnelles;
 - **Base opérationnelle:** valeur courante des données;
 - **Data warehouse:** fournit des infos sous une perspective historique (ex: 5 à 10 dernières années);
- Dans un data warehouse, en général, chaque donnée fait référence au temps;
 - Mais dans une base opérationnelle les données peuvent ne pas faire référence au temps.

Caractéristiques des données d'un DW

❑ Historisées

- Stockage de l'historique des données, **pas de mise à jour**
- Un **référentiel temps** doit être associé aux données

Caractéristiques des données d'un DW

□ Intégrées

- Les données proviennent de différentes sources, de la plupart ou la totalité des applications de l'organisation.
- Construit en intégrant des sources de données multiples et hétérogènes
 - BD relationnelles, fichiers, enregistrements de transactions
- Phase la plus complexe (60 à 90 % de la charge totale d'un projet DW)

Caractéristiques des données d'un DW

❑ Non volatiles

- Une donnée dans un environnement DW ne peut être mise à jour ou supprimée contrairement à celle d'un environnement opérationnel.
- Pas de mises à jour des données dans le DW
- Un support de stockage **séparé**
- Les mises à jour de la base opérationnelle n'ont pas lieu au niveau de la data warehouse
 - N'a pas besoin de modules de gestion de transactions (concurrency, reprise sur panne ...)
 - N'a besoin que de deux opérations pour accéder aux données :
 - **Chargement initial des données** et **interrogation** (lecture).

Exemples d'entrepôt de données

- Amazon Redshift
- Google BigQuery
- Entrepôt IBM Db2
- Microsoft Azure Synapse
- Entrepôt de données autonome
Oracle
- Flocon de neige
- Teradata Vantage

Caractéristiques de l'entrepôt de données

Les entrepôts de données stockent de grandes quantités de données actuelles et historiques provenant de diverses sources. Ils contiennent une gamme de données, depuis les données brutes ingérées jusqu'aux données hautement organisées, nettoyées, filtrées et agrégées.

Les processus d'extraction, de transformation et de chargement (ETL) déplacent les données de leur source d'origine vers l'entrepôt de données. Les processus ETL déplacent les données selon un calendrier régulier (par exemple, horaire ou quotidien), de sorte que les données de l'entrepôt de données peuvent ne pas refléter l'état le plus à jour des systèmes.

Les entrepôts de données ont généralement un schéma relationnel prédéfini et fixe. Par conséquent, ils fonctionnent bien avec des données structurées. Certains entrepôts de données prennent également en charge les données semi-structurées. Une fois les données dans l'entrepôt, les analystes métiers peuvent connecter les entrepôts de données aux outils de BI.

Ces outils permettent aux analystes métiers et aux data scientists d'explorer les données, de rechercher des informations et de générer des rapports pour les parties prenantes de l'entreprise.

Qu'est-ce qu'une base de données ?

Une **base de données** est un ensemble de données ou d'informations. Les bases de données sont généralement accessibles par voie électronique et sont utilisées pour prendre en charge le traitement des transactions en ligne (en anglais Online Transaction Processing) (OLTP). Les systèmes de gestion de base de données (SGBD) stockent les données dans la base de données et permettent aux utilisateurs et aux applications d'interagir avec les données. Le terme « base de données » est couramment utilisé pour référencer à la fois la base de données elle-même ainsi que le SGBD.

Caractéristiques de la base de données

Divers types de bases de données ont vu le jour au cours des dernières décennies. Toutes les bases de données stockent des informations, mais chaque base de données aura ses propres caractéristiques. Les bases de données relationnelles stockent les données dans des tables avec des lignes et des colonnes fixes. Les bases de données non relationnelles (également appelées bases de données NoSQL) stockent les données dans divers modèles, notamment JSON (JavaScript Object Notation), BSON (Binary JSON), des **paires clé-valeur**, des **tables avec des lignes et des colonnes dynamiques**, ainsi que **des nœuds et des arêtes**. **Les bases de données stockent des données structurées et/ou semi-structurées**, selon le type.

Caractéristiques de la base de données

Nous pouvons également trouver des caractéristiques de base de données telles que :

- **Fonctions de sécurité** pour garantir que les données ne sont accessibles qu'aux utilisateurs autorisés.
- **Transactions ACID** (Atomicité, Cohérence, Isolation, Durabilité) pour garantir l'intégrité des données.
- **Langages de requête et API** pour interagir facilement avec les données de la base de données.
- **Index** pour optimiser les performances des requêtes.
- **Recherche en texte intégral.**
- Optimisations pour les appareils mobiles.

Pourquoi utiliser une base de données ?

Si votre application a besoin de stocker des données (et presque toutes les applications interactives le font), elle a besoin d'une base de données. Les applications dans tous les secteurs et cas d'utilisation sont construites sur des bases de données. De nombreux types de données peuvent être stockés dans des bases de données, notamment :

- Dossiers médicaux des patients
- Articles dans une boutique en ligne
- Dossiers financiers Articles et entrées de blog
- Résultats et statistiques sportifs Informations sur les jeux en ligne
- Notes et scores des étudiants
- Les enregistrements des appareils IoT
- Informations sur les applications mobiles

Exemples de bases de données

1. **Bases de données relationnelles** : Oracle, MySQL, Microsoft SQL Server et PostgreSQL
2. **Bases de données orientée documents**: MongoDB et CouchDB
3. **Bases de données orientée clé-valeur**: Redis et DynamoDB
4. **Bases de données orientée colonnes** : Cassandra et Hbase
5. **Bases de données basée sur les graphiques** : Neo4j et Amazon Neptune

Les de Base de Données NoSQL Populaires

Base de données Orienté Colonne:

1. Hbase
2. Hypertable
3. Cassandra
4. Accumulo

Bases de données clé-valeur :

1. Riak
2. Infinispan
3. Hazelcast
4. Redis
5. Voldemort

Base de données Orienté Documents:

1. MongoDB
2. CouchDB
3. Terrastore
4. RavenDB

Bases de données basées sur les graphes:

1. Neo4J
2. InfiniteGraph
3. InfoGrid
4. HypergraphDB
5. AllegroGraph

Qu'est-ce qu'un Lac de Données ou Data Lake

Un lac de données est un référentiel de données provenant de sources disparates qui sont stockées dans leur format brut d'origine. Comme les entrepôts de données, les lacs de données stockent de grandes quantités de données actuelles et historiques. Ce qui distingue les lacs de données, c'est leur capacité à stocker des données dans une variété de formats, notamment JSON, BSON, CSV, TSV, Avro, ORC et Parquet.

En règle générale, l'objectif principal d'un lac de données est d'analyser les données pour obtenir des informations. Cependant, les organisations utilisent parfois les lacs de données simplement pour leur stockage bon marché, dans l'idée que les données pourraient être utilisées à des fins d'analyse à l'avenir.

Un lac de données est-il une base de données ?

Vous vous demandez peut-être : « Un lac de données est-il une base de données ? Un lac de données est un référentiel de données stockées de diverses manières, notamment dans des bases de données. Avec **les outils et technologies modernes, un lac de données peut également constituer la couche de stockage d'une base de données.** Des outils tels que Starburst, Presto, Dremio et Atlas Data Lake peuvent donner une vue semblable à une base de données sur les données stockées dans votre lac de données. Dans de nombreux cas, ces outils peuvent alimenter les mêmes charges de travail analytiques qu'un entrepôt de données.

Caractéristiques du lac de données

Les lacs de données stockent de grandes quantités de données **structurées, semi-structurées et non structurées**. Ils peuvent tout contenir, des données relationnelles aux documents JSON en passant par les PDF et les fichiers audio.

Les données n'ont pas besoin d'être transformées pour être ajoutées au lac de données, ce qui signifie que les données peuvent être ajoutées (ou « ingérées ») de manière incroyablement efficace sans planification préalable.

Les principaux utilisateurs d'un lac de données peuvent varier en fonction de la structure des données. Les **analystes métiers** pourront obtenir des informations lorsque les données seront plus structurées.

Caractéristiques du lac de données

Lorsque les données sont moins structurées, l'analyse des données nécessitera probablement l'expertise de développeurs, de data scientists ou d'ingénieurs de données.

La nature flexible des lacs de données permet aux **analystes métiers** et aux data scientists de rechercher des modèles et des informations inattendus. La nature brute des données combinée à leur volume permet aux utilisateurs de résoudre des problèmes dont ils n'avaient peut-être pas conscience lors de la configuration initiale du lac de données. **Les données des lacs de données peuvent être traitées avec une variété de systèmes OLAP et visualisées avec des outils BI.**

Pourquoi utiliser un lac de données ?

Les **lacs de données constituent** un moyen rentable de stocker d'énormes quantités de données. Utilisez un lac de données lorsque vous souhaitez obtenir des informations sur vos données actuelles et historiques sous leur forme brute sans avoir à les transformer et à les déplacer. Les lacs de données prennent également en charge l'apprentissage automatique et l'analyse prédictive. À l'instar des entrepôts de données, les lacs de données ne sont pas destinés à satisfaire les besoins de transaction et de concurrence d'une application.

Exemples de lacs de données

Les lacs de données peuvent fournir des capacités de stockage et de calcul, indépendamment ou ensemble.

ci-dessous des exemples de technologies qui fournissent un stockage flexible et évolutif pour la création de lacs de données :

AWS S3 Azure Data Lake Storage Gen2

Stockage Google Cloud

D'autres technologies permettent d'organiser et d'interroger les données dans des lacs de données, notamment :

[MongoDB Atlas Data Lake.](#)

AWS Athena.

Presto.

Starburst.

Databricks SQL Analytics.

Notion de Data mart


Pourquoi des data marts ?

Les Data Warehouses étant, en général, **très volumineux** et très **complexes à concevoir**, on décide de les diviser en bouchées plus faciles à créer et entretenir que nous appelons **data marts**.

Notion de Data mart

Un **data mart** est une forme simple d'entrepôt de données qui se concentre sur **un seul sujet** (ou domaine fonctionnel), et qui extrait donc des données **d'un nombre limité de sources telles que les ventes, la finance ou le marketing**. Les data marts sont souvent construits et contrôlés par un seul service au sein d'une organisation. Les sources peuvent être des systèmes **opérationnels internes, un entrepôt de données central ou des données externes**. Étant donné que les data marts ne couvrent généralement qu'un sous-ensemble des données contenues dans un entrepôt de données, ils sont souvent plus faciles et plus rapides à mettre en œuvre.

Notion de Data mart



Notion de Data mart

Définition:

«Un **Data mart** est un sous-ensemble de données dérivées du DW ciblé sur un sujet unique».

Un **Data mart** est un sous-ensemble d'un DW destiné à fournir des données aux utilisateurs, et souvent spécialisé vers un groupe ou un type d'affaire. Il s'agit d'un extrait de l'ensemble des données d'une entreprise, ne contenant que le nécessaire.

Quelques exemples de Data mart :


- Datamart **commercial**
- Datamart **RH**
- Datamart **financier**

Difference entre Data warehouse et data mart

Un data warehouse et un data mart se distinguent par le spectre qu'il recouvre :

- ❑ Le **data warehouse** recouvre l'ensemble des données et problématiques d'analyse visées par l'entreprise.
- ❑ Le **data mart** recouvre une partie des données et problématiques liées à un métier ou un sujet d'analyse en particulier.

Un **data mart** est fréquemment un sous-ensemble du data warehouse de l'entreprise, obtenu par extraction et agrégation des données de celui-ci.



Difference entre Data warehouse et data mart

Difference between data warehouse and data mart	
Data warehouse	Data mart
enterprise-wide data	department-wide data
multiple subject areas	single subject area
difficult to build	easy to build
takes more time to build	less time to build
larger memory	limited memory

Les Types de Data Marts

Il existe fondamentalement trois types de data marts : dépendant, indépendant et une combinaison des deux appelée hybride. Ce qu'ils ont en commun, c'est que tous les trois présentent un ensemble de données spécifique à un sujet aux équipes métiers (business teams) qui en tireront le plus grand profit. Les pionniers des entrepôts de données **Ralph Kimball** et **Bill Immon** ont défini les deux premiers.

Le **modèle dépendant** d'Immon préconise que les données entrent dans un entrepôt de données central, puis soient segmentées en data marts individuels.

En revanche, Kimball a proposé le **modèle indépendant**, dans lequel les données entrent directement dans des data marts individuels, puis sont agrégées dans un entrepôt de données. Avec les data marts hybrides, les organisations prennent le meilleur de chaque modèle et l'appliquent à différents services en fonction de leurs besoins.(Modifié)Restaurer la traduction d'origine

Les Types de Data Marts


- ☐ Datamart dépendant
- ☐ Datamart indépendant
- ☐ Datamart hybride

Datamart dépendant

Un **datamart dépendant** est construit sur un entrepôt de données central. En pratique, l'entrepôt de données contrôle toutes les données. Toutes les sources de données, y compris les données tierces sous licence, sont d'abord chargées dans l'entrepôt de données central, puis le sous-ensemble des données nécessaires est propagé vers le datamart.

L'un des avantages de ce modèle est que la majeure partie de l'administration des données se déroule dans le référentiel central, ce qui nécessite moins de savoir-faire technique au niveau du datamart. De plus, les problèmes critiques tels que la technologie, les données et le stockage (y compris les sauvegardes) sont traités de manière centralisée. Inversement, si l'entrepôt de données est hors ligne pour une raison quelconque, planifiée ou non, les datamarts dépendants peuvent tomber en panne avec lui.

Datamart dépendant




Datamart indépendant

Les datamarts indépendants ne s'appuient pas sur un entrepôt de données central. En fait, ce modèle propose qu'un entrepôt de données central n'ait même pas nécessairement besoin d'exister. Au lieu de cela, des datamarts indépendants peuvent être mis en place pour agir comme des entités autonomes — des mini-entrepôts de données axés sur les besoins de divisions spécifiques. L'un des avantages de ce modèle est que les unités commerciales individuelles peuvent gérer le datamart qui leur convient le mieux.

Bien entendu, cette indépendance s'accompagne du besoin d'une expertise administrative technique dans chaque datamart. De plus, si les données doivent être agrégées dans plusieurs datamarts (pour des rapports au niveau de la direction, par exemple), vous devrez créer des requêtes qui accèdent à plusieurs datamarts. Par conséquent, avec des datamarts indépendants, il devient plus important d'instaurer une taxonomie organisationnelle qui fournit une dénomination standard pour les tables et les champs (ou un thésaurus qui mappe les tables et les champs entre tous les datamarts de l'entreprise) pour faciliter la génération de rapports inter-datamart.

Datamart indépendant



Datamart Hybride

Certaines organisations trouvent pratique d'envisager un modèle hybride dans lequel certains datamarts dépendent d'un entrepôt central et d'autres existent de manière autonome. Par exemple, il peut être plus efficace d'utiliser ce modèle comme étape de transition pour de nouveaux datamarts. De nouvelles sources de données spécifiques à un sujet peuvent être plus faciles à déployer en tant que datamarts indépendants. Une fois qu'elles ont prouvé leur valeur, elles peuvent être déployées dans l'entrepôt de données central, si nécessaire. L'entreprise qui acquiert peut traiter les données de la filiale comme un datamart indépendant tout en prévoyant de les rendre conformes aux propres politiques de données de l'entreprise par la suite, puis de les intégrer.


Les ressources humaines nécessaires à l'exécution du modèle hybride sont un élément important à prendre en compte. Il nécessite une expertise administrative technique au niveau de l'entrepôt de données central et au niveau du datamart.

Les Types de Data Marts


Le type de datamart qu'une entreprise choisit dépend de nombreux facteurs, notamment de la manière dont elle est organisée. Ces quatre questions peuvent aider une organisation à déterminer le type qui lui convient le mieux :

1. Les unités métier sont-elles gérées comme des entités autonomes ou sont-elles considérées comme faisant partie d'un tout ?
2. La culture de l'entreprise encourage-t-elle le partage d'informations ou les unités commerciales individuelles accumulent-elles des connaissances ?
3. Les unités métier individuelles disposent-elles du personnel nécessaire pour gérer les subtilités de la gestion des données ?
4. De même, l'équipe de base de données centrale s'engage-t-elle à répondre rapidement aux besoins des unités commerciales distinctes ou la bureaucratie et les égos interfèrent-ils ?

Data warehouse vs Big Data



Architecture de Data warehouse




Architecture de Data warehouse


Architecture prônée par **Bill Inmon** :

- ❑ **L'ODS** : est l'acronyme pour Operational Data Store ou (Magasin de données opérationnelles). Il joue deux rôles :
 - ❖ sert à stocker les données extraites des systèmes sources.
 - ❖ intègre les données sources dans le but de présenter toute l'information nécessaire à prendre des décisions.
- ❑ **L'Entreprise Data warehouse** : Les données de l'ODS sont transférées vers le **DWH**. Ce dernier est central (d'où son appellation Enterprise Data Warehouse (EDW)). Il contient toutes les données de l'entreprise.
- ❑ **Les data marts dépendants** : Ils peuvent être alimentés soit de L'EDW soit de l'ODS.
- ❑ **La zone de présentation** : Une fois les données chargées dans le Data warehouse et les data marts dépendants, les utilisateurs peuvent y accéder pour exécuter leurs requêtes Ad hoc, programmer les rapports, analyser et visualiser l'information...


Architecture type de Data warehouse



Architecture type de Data warehouse



Architecture générale du Data warehouse



Les Différentes zones de l'Architecture du DW

❑ Zone de préparation (Staging area)

- Zone temporaire de stockage des données extraites
- Réalisation des transformations avant l'insertion dans le DW:
 - **Nettoyage**
 - **Normalisation...**
- Données souvent détruites après chargement dans le DW

❑ Zone de stockage (DW, DM)

- On y transfère les données nettoyées
- Stockage permanent des données

❑ Zone de présentation

- Donne accès aux données contenues dans le DW
- Peut contenir des outils d'analyse programmés:
 - **Requêtes/Rapports**
 - **Analyse (OLAP), Tableaux de bords**
 - **Datamining**

Modélisation Conceptuelle des Data Warehouses

- ❑ **Schéma en étoile:** Au milieu, une table de faits connectée à un ensemble de tables de dimensions.
- ❑ **Schéma flocon de neige (snowflake):** Un raffinement du précédent où certaines tables de dimensions sont normalisées (donc décomposées)
- ❑ **Constellation de faits:** Plusieurs tables de faits partagent quelques tables de dimension (constellation d'étoiles)

Notion de Dimension

Lorsqu'on fait un schéma de BD pour un système d'information classique, on parle en termes **de tables et de relations**. **Une table étant une représentation d'une entité et une relation une technique pour lier ces entités**. Et bien en Business Intelligence (BI), on parle en termes **de Dimension et de Faits**.

On entend par dimensions les axes avec lesquels on veut faire l'analyse. Une dimension est tout ce qu'on utilisera pour faire nos analyses. La table de dimensions contient des attributs descriptifs qui décrivent un aspect spécifique de la table de faits. Il peut y avoir une **dimension Client**, une **dimension Produit**, **dimension Temps**, une **dimension Géographie** (pour faire des analyses par secteur géographique), etc.

Notion de table de Dimension

Une **dimension** est une structure qui classe **les faits** et **les mesures** afin de permettre aux utilisateurs de répondre à des questions professionnelles. Dans l'entrepôt de données, elle est une collection d'information de référence sur un évènement mesurable.

Une table de dimension décrit les attributs de la dimension de l'analyse, et les niveaux de granularité de cette dimension.

Une **table de dimension** contient les détails sur **les faits**, les informations descriptives des valeurs numériques de la table de faits.

Notion de Fait et Mesure

Les faits sont ce sur quoi va porter l'analyse. Un fait est tout ce qu'on voudra analyser.

Les faits sont le sujet de l'analyse. Ils représentent des tables qui contiennent des informations opérationnelles et qui retracent la vie de l'entreprise.

Les **faits** dans un entrepôt de données doivent être **quantitatifs**. Il peut s'agir du **montant des ventes**, du **nombre d'unités vendues** d'un produit.

Une table de faits contient **les valeurs numériques de ce qu'on désire mesurer** (analyser), et les **clés associées aux dimensions**.

Notion de Fait et Mesure

Une **mesure** est un indicateur numérique représentant une grandeur. C'est un calcul analytique exécuté sur des données stockées afin de produire des résultats pouvant être lus sous la forme d'états ou analysés pour faciliter la prise de décision.

Exemple de mesure: le chiffre d'affaire ou le prix d'un produit.

Notion de Table de Fait

Une table de faits contient des colonnes des faits à analyser (mesures); et des clés étrangères vers les tables de dimension.

Par exemple on nous pouvons avoir :

- des **tables de faits pour les ventes** (*chiffre d'affaire net, quantités et montants commandés, quantités facturées, quantités retournées, volumes des ventes, etc.*)
- des **tables de faits pour les stocks** (*nombre d'exemplaires d'un produit en stock, niveau de remplissage du stock, taux de roulement d'une zone, etc.*),
- des **tables de faits pour les ressources humaines** (*performances des employés, nombre de demandes de congés, nombre de démissions, taux de roulement des employés, etc.*).

Table de Dimension et Table de Fait


Les **tables de dimensions** font partie intégrante d'une **table de faits**. Les **tables de dimensions** contiennent le **contexte textuel** associé à **un événement de mesure de processus métier**. Les **tables de dimensions** décrivent le « **qui, quoi, où, quand, comment et pourquoi** » associé à **l'événement de mesure de processus métier**.

- Avec les modèles dimensionnels, **on peut ajouter des dimensions complètement nouvelles au schéma à condition qu'une valeur unique de cette dimension soit définie pour chaque ligne de faits existante.**
- De même, **on peut ajouter de nouveaux faits à la table de faits, en supposant que le niveau de détail est cohérent avec la table de faits existante.**


Table de Dimension et Table de Fait

La complémentarité des tables de faits et de dimensions est de les voir traduits dans un rapport. Comme l'illustre la **Figure 1-6**, les attributs de dimension fournissent **les filtres** et **l'étiquetage** du rapport, *tandis que les tables de faits fournissent les valeurs numériques du rapport.*

Les attributs dimensionnels et les faits forment un rapport simple



La requête SQL Correspondante pour créer ce rapport



```
SELECT
    store.district_name,
    product.brand,
    sum(sales_facts.sales_dollars) AS "Sales Dollars"
FROM
    store,
    product,
    date,
    sales_facts
WHERE
    date.month_name="January" AND
    date.year=2013 AND
    store.store_key = sales_facts.store_key AND
    product.product_key = sales_facts.product_key AND
    date.date_key = sales_facts.date_key
GROUP BY
    store.district_name,
    product.brand
```

La requête SQL Correspondante pour créer ce rapport

```
SELECT
    store.district_name,
    product.brand,
    sum(sales_facts.sales_dollars) AS "Sales Dollars"
FROM
    store,
    product,
    date,
    sales_facts
WHERE
    date.month_name="January" AND
    date.year=2013 AND
    store.store_key = sales_facts.store_key AND
    product.product_key = sales_facts.product_key AND
    date.date_key = sales_facts.date_key
GROUP BY
    store.district_name,
    product.brand
```


Processus de Conception Dimensionnelle

Les quatre décisions clés prises lors de la conception d'un modèle dimensionnel sont les suivantes :

1. Sélectionnez **le processus métier**.
2. Déclarez **le grain**.
3. Identifiez **les dimensions**.
4. Identifiez **les faits**

Les réponses à ces questions sont déterminées en tenant compte des besoins de l'entreprise ainsi que des réalités des données sources sous-jacentes lors des sessions de modélisation collaborative. Suite aux déclarations de processus métier, de grain, de dimension et de fait, l'équipe de conception détermine les noms de table et de colonne, des exemples de valeurs de domaine et des règles métier.

Les Processus Métier

Les **processus métier** sont les activités opérationnelles effectuées par votre organisation, telles que **la prise d'une commande**, **le traitement d'une réclamation d'assurance**, **l'inscription des étudiants à un cours** ou **la capture instantanée de chaque compte chaque mois**.

Les événements de processus métier génèrent ou capturent **des mesures de performances** qui se traduisent **en faits** dans une **table de faits**. La plupart des table de faits se concentrent sur les résultats d'un seul processus métier. Le choix du processus est important car il définit un objectif de conception spécifique et permet de déclarer le grain, les dimensions et les faits. Chaque processus métier correspond à une ligne dans la matrice de bus de l'entrepôt de données d'entreprise.

Grain

La déclaration du grain est l'étape cruciale d'une conception dimensionnelle. **Le grain établit exactement ce que représente une ligne de la table de faits.**

Le **grain** doit être déclaré avant de choisir **les dimensions** ou **les faits** car chaque **dimension** ou **fait** *candidat* doit être cohérent avec le grain.

Le *grain atomique* fait référence au niveau le plus bas auquel les données sont capturées par un processus métier donné.

Il est fortement encourager de commencer par se concentrer sur les données à granularité atomique.

Les grains récapitulatifs cumulés sont importants pour l'optimisation des performances, mais ils présupposent les questions courantes de l'entreprise.

Chaque grain de table de faits proposé donne lieu à une table physique distincte.

Différents grains ne doivent pas être mélangés dans la même table de faits.

Dimensions pour le contexte descriptif

Les dimensions fournissent le contexte « qui, quoi, où, quand, pourquoi et comment » entourant un événement de processus métier. Les tables de dimensions contiennent les attributs descriptifs utilisés par les applications BI pour filtrer et regrouper les faits. **En gardant à l'esprit le grain d'une table de faits, toutes les dimensions possibles peuvent être identifiées.** Dans la mesure du possible, **une dimension doit avoir une valeur unique lorsqu'elle est associée à une ligne de faits donnée.**

Les **tables de dimensions** sont parfois appelées « **l'âme** » de l'entrepôt de données car elles contiennent les points d'entrée et les étiquettes descriptives qui permettent d'exploiter le système DW/BI pour l'analyse commerciale.

Faits pour les mesures

Les faits sont les mesures résultant d'un événement de processus métier et sont presque toujours numériques.

Une ligne de table de faits a une relation de type un-à-un avec un événement de mesure tel que décrit par le grain de la table de faits.

Ainsi, une table de faits correspond à un événement physique observable, et **non aux exigences d'un rapport particulier.**

Dans une table de faits, seuls les faits cohérents avec le grain déclaré sont autorisés. Par exemple, dans une transaction de vente au détail, la quantité d'un produit vendu et son prix calculé sont de bons faits, alors que le salaire du gérant du magasin n'est pas admissible.

Notion de Hiérarchie

Une **hiérarchie** est une organisation logique des membres d'une dimension de manière hiérarchique.

Par exemple, **une hiérarchie** pour la dimension **Temps** : le plus haut niveau serait **l'année**, contiendrait **le mois**, puis **la semaine**, puis **le jour** et ainsi de suite.

Une **hiérarchie dimensionnelle** est formée d'attributs ayant des relations 1 à plusieurs entre eux. On pourrait avoir la hiérarchie suivante :

catégorie → sousCatégorie → idProduit

qui se traduit comme “une catégorie contient plusieurs sous-catégories, chacune d'elle renfermant plusieurs produits.

Notion de Hiérarchie

On pourrait également définir des hiérarchies comportant d'autres attributs, par exemple :

département → catégorie → sousCatégorie → marque → idProduit

Si on imagine la hiérarchie comme une arborescence de répertoires, l'attribut marque dans cette hiérarchie correspondrait au répertoire suivant :

/[département]/[catégorie]/[sousCatégorie]/[marque]

Granularité des dimensions


□ Granularité des dimensions

- Une dimension contient des membres organisés en hiérarchie
- Chacun des membres appartient à un niveau hiérarchique (ou niveau de granularité) particulier
- Granularité d'une dimension : nombre de niveaux hiérarchiques



ETL


L'ETL sert à transposer le modèle entité-relation des bases de données de production ainsi que les autres modèles utilisés dans les opérations de l'entreprise, **en modèle à base de dimensions et de faits.**



Exemple de modèle dimensionnel en étoile

Exemple modélisation Data Warehouse

Les **dimensions**, **hiérarchies**, **faits** et **mesures** sont utilisés dans la **modélisation d'un DW ou un Data mart** comme la montre la figure ci-dessous :



Data Warehousing and Dimensional Modeling

L'entrepasage de données consiste à collecter, stocker et gérer des données provenant de plusieurs sources pour prendre en charge l'analyse et la création de rapports commerciaux.


La modélisation dimensionnelle est un aspect essentiel de l'entrepasage de données, car elle permet aux entreprises de structurer leurs données pour prendre en charge des analyses et des rapports pratiques. La modélisation dimensionnelle profite à l'entrepasage de données en fournissant une structure optimisée pour les performances des requêtes et en aidant les entreprises à analyser les données sous plusieurs perspectives. Elle permet également aux entreprises d'ajouter facilement de nouvelles sources de données et dimensions à mesure que leurs besoins évoluent.

La Modélisation Dimensionnelle

La modélisation dimensionnelle est une technique de modélisation de données utilisée dans l'entreposage de données qui permet aux entreprises de structurer les données **pour optimiser l'analyse et le reporting**. Cette méthode implique d'organiser les données en dimensions et en faits, où les dimensions sont utilisées pour décrire les données et les faits sont utilisés pour quantifier les données.

Par exemple, supposons qu'une entreprise souhaite **analyser les données de ventes**. Dans ce cas, **les dimensions** pourraient inclure *les clients, les produits, les régions et le temps*, tandis que **les faits** pourraient être *le nombre de produits vendus, le revenu total généré et le bénéfice réalisé*.

La Modélisation Dimensionnelle



Les données sont ensuite structurées selon un schéma en étoile ou en flocon de neige, avec la table de faits au centre et les tables de dimensions connectées via des clés étrangères.

Chaque table de dimensions contient des attributs descriptifs qui décrivent un aspect spécifique de la table de faits.

La Modélisation Dimensionnelle

La modélisation dimensionnelle facilite la compréhension des données par les utilisateurs métiers. **Au lieu d'avoir l'information et les relations divisées en plusieurs dizaines de tables**, les données sont représentées comme une table de faits refermant **les mesures d'un évènement métier** (ou évènement d'affaires) (ex : **le montant d'une vente, le profit**, etc.), et **des tables de dimensions** donnant le contexte à cet évènement. *L'autre avantage de la modélisation dimensionnelle est une meilleure performance lors des requêtes analytiques car les tables sont dénormalisées et donc il y a moins de jointures à faire.*


Techniques de Modélisation Dimensionnelle

Schéma en étoile


Le schéma en étoile est la technique de modélisation dimensionnelle la plus simple et la plus courante. Dans un schéma en étoile, la table de faits est au centre et connectée via une ou plusieurs clés étrangères aux tables de dimensions. **La table de faits contient les valeurs numériques ou les mesures analysées**, tandis que **les tables de dimensions contiennent les attributs qui décrivent les données**.

Le schéma en étoile est une méthode simple et efficace de modélisation dimensionnelle, facile à comprendre et à utiliser. **Il convient aux entrepôts de données qui nécessitent des requêtes rapides et efficaces.**


Schéma en étoile



Exemple de schéma en étoile



Exemple de schéma en étoile



Techniques de Modélisation Dimensionnelle


Schéma du flocon de neige

Le schéma en flocon de neige est une technique de modélisation dimensionnelle plus complexe utilisée lorsqu'il existe plusieurs niveaux de granularité (hiérarchie) au sein d'une dimension.


Dans un schéma en flocon de neige, les tables de dimensions sont normalisées, ce qui signifie qu'elles sont divisées en plusieurs tables pour réduire la redondance des données. Cette normalisation aboutit à un schéma plus complexe qui ressemble à un flocon de neige, d'où son nom.

Le schéma en flocon de neige convient aux entrepôts de données vastes et complexes nécessitant une analyse et un reporting approfondis des données. Cependant, il peut être plus difficile à utiliser et à maintenir que le schéma en étoile.

Schéma du flocon de neige



Exemple de schéma Snowflake




Techniques de Modélisation Dimensionnelle


Constellation de faits

S'il y a plusieurs modèles en étoile liés entre eux par des dimensions communes, le nouveau modèle constitué sera appelé modèle **en constellation**. Plusieurs tables de faits partagent quelques tables de dimension (constellation d'étoiles).

Exemple de Constellation de faits



Exemple de Constellation de faits



Avantages de la modélisation dimensionnelle

La **modélisation dimensionnelle** est **une technique précieuse pour organiser et analyser les données** de manière à prendre en charge des **requêtes efficaces, une analyse complexe et une prise de décision éclairée.**

La **modélisation dimensionnelle** fournit une structure claire et cohérente qui améliore la qualité des données et facilite l'évolutivité, ce qui le rend un outil essentiel pour l'entreposage de données et la business intelligence.

La **modélisation dimensionnelle** est également très flexible et adaptable. **De nouvelles dimensions et mesures peuvent être facilement ajoutées au modèle de données dimensionnelles au fur et à mesure que les exigences métier évoluent.** Cela facilite la mise à jour de l'entrepôt de données et sa pertinence par rapport aux besoins de l'entreprise.

Avantages de la modélisation dimensionnelle

Ci-dessous quelques avantages de l'utilisation de la modélisation dimensionnelle dans un entrepôt de données :

❑ Performance améliorée

La modélisation dimensionnelle offre de meilleures performances de requête car elle simplifie le schéma et élimine les jointures inutiles. Les requêtes peuvent être exécutées plus rapidement car elles impliquent moins de tables.

❑ Flexibilité améliorée

La modélisation dimensionnelle offre une plus grande flexibilité, permettant d'ajouter ou de supprimer facilement des données de l'entrepôt sans affecter le schéma existant. Cela signifie que les organisations peuvent réagir rapidement aux changements de leurs besoins commerciaux et adapter leur entrepôt de données en conséquence.

Avantages de la modélisation dimensionnelle

❑ Convivialité améliorée

La modélisation dimensionnelle est conviviale car elle organise les données de manière facile à comprendre et à utiliser. Cela permet aux utilisateurs d'accéder et d'analyser plus facilement les données nécessaires.

❑ Évolutivité accrue

La modélisation dimensionnelle est évolutive car elle permet aux organisations d'ajouter de nouvelles dimensions ou faits à l'entrepôt de données. Cela signifie que les organisations peuvent étendre leur entrepôt de données pour répondre aux demandes croissantes de données sans repenser l'intégralité du schéma.

Avantages de la modélisation dimensionnelle

❑ Documentation

La modélisation des données fournit une documentation claire et structurée des données d'une organisation. Cela permet de garantir l'exactitude, la cohérence et la fiabilité des données tout en identifiant les problèmes potentiels. De plus, la modélisation des données peut améliorer la communication entre les différentes parties prenantes, conduisant ainsi à de meilleures prises de décision et à de meilleurs résultats commerciaux.

Étapes pour mettre en œuvre la modélisation dimensionnelle

- 1. Identification du processus métier**
- 2. Déterminer les données à analyser**
- 3. Identification des dimensions**
- 4. Identification des faits**
- 5. Identifiez le grain**
- 6. Concevoir le schéma**
- 7. Alimenter l'entrepôt de données**
- 8. Test de l'entrepôt de données**

Étapes pour mettre en œuvre la modélisation dimensionnelle

1. Identification du processus métier

La première étape de la mise en œuvre de la modélisation dimensionnelle **consiste à identifier les exigences métier et le processus métier que l'entrepôt de données prendra en charge.** Cela implique de déterminer les objectifs métier qui doivent être soutenus par les indicateurs de performance clés (KPI) qui seront utilisés pour mesurer le succès du processus.

Étapes pour mettre en œuvre la modélisation dimensionnelle

2. Déterminer les données à analyser

Une fois le processus métier identifié, l'étape suivante consiste à **déterminer quelles données doivent être analysées**. Cela comprend l'identification des sources de données pertinentes et des éléments de données spécifiques qui doivent être inclus dans le modèle.

3. Identification des dimensions

La troisième étape consiste à **identifier les dimensions qui seront utilisées pour décrire les données**. Ces dimensions doivent être basées sur les KPI identifiés lors de la première étape et pertinents pour le processus métier.

Étapes pour mettre en œuvre la modélisation dimensionnelle

4. Identification des faits

La quatrième étape consiste à **identifier les faits qui seront analysés dans l'entrepôt de données**. Ces faits doivent être basés sur les KPI spécifiés à la première étape et pertinents pour le processus métier.

5. Identifiez le grain

Le grain fait référence au niveau de détail auquel les données seront stockées et analysées.

Par exemple, dans un modèle de données de ventes, **les grain peuvent se situer au niveau des transactions de vente individuelles ou au niveau des ventes totales quotidiennes**. L'identification du grain est importante car elle détermine le niveau de détail auquel les données seront stockées et peut affecter les performances et la convivialité du modèle de données.

Étapes pour mettre en œuvre la modélisation dimensionnelle

6. Concevoir le schéma

La dernière étape consiste à concevoir le schéma. Cela implique la création de tableaux de faits et de dimensions basés sur les dimensions et les faits identifiés aux étapes trois et quatre.

7. Alimenter l'entrepôt de données

La septième étape consiste à alimenter l'entrepôt de données avec les données des systèmes sources. Cela implique l'extraction, la transformation et le chargement (ETL) des données dans l'entrepôt de données.

Étapes pour mettre en œuvre la modélisation dimensionnelle

8. Test de l'entrepôt de données

La dernière étape consiste à tester l'entrepôt de données pour s'assurer qu'il répond aux exigences identifiées lors de la première étape. Cela implique d'exécuter des requêtes sur l'entrepôt de données pour garantir que les données sont exactes, complètes et cohérentes. Identifier et résoudre tout problème lors des tests est essentiel pour garantir le bon fonctionnement de l'entrepôt de données.

OLAP

OLAP (On-Line Analytical Processing) est défini comme étant « ... ***le nom donné à l'analyse dynamique requise pour créer, manipuler, animer et synthétiser l'information par des modèles d'analyse de données selon des formules*** » Codd et al. [1993].

En d'autres termes, il s'agit d'applications de modélisation descriptive et d'analyse exploratoire des données, conçues à des fins de prise de décision.

Caractéristiques d'utilisation : OLTP vs OLAP

Caractéristiques	OLTP	OLAP
Portée de l'interaction utilisateur	Transaction	BD entière
Qte de data affectées par l'interaction	Enregistrements individuels	Groupes d'enregistrements
Temps de réponse	Secondes	Secondes à minutes
Mode d'utilisation	Stable	Dynamique
Nature des données	Primitives (au plus bas niveau de détail)	Dérivées (agrégées)
Mode d'accès à la BD	Accès prédéfini	Accès indéfini ou dynamique
Volatilité des données	Elevée	Faible
Priorités	Haute performance, grande disponibilité	Grande souplesse, grande autonomie

Analyse multidimensionnelle

L'analyse multidimensionnelle **consiste à modéliser des données selon plusieurs axes**. L'exemple le plus classique : le calcul du chiffre d'affaires par catégorie de client sur une gamme de produit donnée combine trois axes (le chiffre réalisé, la catégorie de clients et la ligne de produits). De nombreux autres axes supplémentaires peuvent être définis: zone géographique ou équipe commerciale en charge des opérations par exemple. Le cube "OLAP" (pour Online analytical processing) désigne la technologie analytique qui s'applique à ce modèle de représentation.


Les structures multidimensionnelles OLAP permettent d'analyser des indicateurs (ventes, chiffre d'affaires, transactions...) et de les explorer suivants plusieurs dimensions (temps, produit, Catégorie...). Les choix de l'architecture OLAP vont influencer sur toutes les composantes du système décisionnel : performance, volumétrie, temps de requête.

Analyse multidimensionnelle

Cube OLAP(Online Analytical Processing)

Un cube OLAP est une structure de données multidimensionnelle stockant les faits comme des mesures indexées par plusieurs dimensions. Ainsi, chaque cellule d'un cube représente la mesure ou valeur quantitative d'un fait sur le croisement de plusieurs dimensions.

Les Différentes zones de l'Architecture du DW



Fonctionnement d'un cube OLAP

Vendeur	Produit	Date de vente	Prix de vente
Juvénal	Accessories	01/04/2001	800
Myles	Bikes	09/05/2001	1400
Yvan	Clothing	02/02/2002	500
Yvan	Components	15/03/2002	1000
Juvénal	Bikes	02/03/2002	1800
Juvénal	Bikes	10/03/2003	2000
Myles	Components	12/10/2003	700
Myles	Bikes	25/12/2003	2200
Juvénal	Components	10/01/2004	500
.....			
Yvan	Bikes	15/11/2004	2500

Supposons que nous souhaitons calculer **la somme des ventes par produit et par année**. La représentation de ce tableau sous forme d'une structure multidimensionnelle fournit le cube OLAP suivant:




Figure : représentation du tableau en cube OLAP. Les 3 colonnes de catégories deviennent des dimensions dans le cube, tandis que le prix devient la mesure qui est la valeur correspondante au croisement des 3 dimensions simultanément.

Fonctionnement d'un cube OLAP




Figure : représentation du tableau en cube OLAP. Les 3 colonnes de catégories deviennent des dimensions dans le cube, tandis que le prix devient la mesure qui est la valeur correspondante au croisement des 3 dimensions simultanément

Fonctionnement d'un cube OLAP


Dans le cube ci-dessus, nous avons trois **dimensions** : **Année**, **Vendeur** et **Produit** ; la **mesure** c'est **le prix de vente**.

Pour rendre le cube fonctionnel, on applique à ses cellules (donc à la mesure) une **fonction d'agrégation**, cette fonction peut être soit **une somme**, **une moyenne**, **un maximum** ou **un minimum**, bref **toute fonction qui regroupe ou compare un ensemble de données**.

Pour faciliter la représentation graphique du cube, dans cet exemple la **somme des mesures** uniquement a été présenté sur la première face, mais en réalité, toutes les cellules comportent des valeurs pour chaque recoupement de dimensions et répondent à une requête bien précise.

Fonctionnement d'un cube OLAP

Par exemple la cellule qui est à l'intersection de l'attribut « *Bikes* » de la dimension Produit et de l'attribut « Juvénal » de la dimension Vendeur a pour somme de ventes 3800; ceci correspond à la requête chiffre d'affaire réalisé par le Vendeur Juvénal sur les Produits « Bikes » depuis 2001. Cependant, certains croisements de dimensions peuvent ne pas avoir de valeur (agrégation nulle dans ce cas), c'est ce qui explique que certaines cellules du cube soient vides.



Schémas en étoile et cubes OLAP

Les schémas en étoile sont des structures dimensionnelles déployées dans un système de gestion de base de données relationnelle (SGBDR). Ils se composent généralement de tables de faits liées aux tables de dimensions associées via des relations de clé primaire/étrangère.

Un cube de traitement analytique en ligne (OLAP) est une structure dimensionnelle implémentée dans une base de données multidimensionnelle; son contenu peut être équivalent à un schéma relationnel en étoile, ou son contenu peut être le plus souvent dérivé, d'un schéma relationnel en étoile. Un cube OLAP contient des attributs et des faits dimensionnels, mais il est accessible via des langages dotés de plus de capacités analytiques que SQL, tels que XMLA et MDX. Les cubes OLAP sont inclus dans cette liste de techniques de base car un cube OLAP constitue souvent l'étape finale du déploiement d'un système DW/BI dimensionnel, ou peut exister sous la forme d'une structure agrégée basée sur un schéma en étoile relationnel plus atomique.

Conception d'une base de données multidimensionnelle

La **conception d'un cube OLAP** passe par la transformation du modèle de données des bases de données opérationnelles en *modèle multidimensionnel* du Data Warehouse, plus adéquat pour les **requêtes multidimensionnelles**.

Pour ce faire, on utilise une technique de modélisation particulière qu'on appelle **la modélisation multidimensionnelle**.

La modélisation multidimensionnelle est *une technique de modélisation qui consiste à représenter les données sous forme de points dans un espace à plusieurs dimensions*. L'intérêt est d'offrir à l'utilisateur la capacité de faire des **requêtes multidimensionnelles** ou **agrégations** par **axe de l'espace**.

Les Operations OLAP

- 1. Roll-up**
- 2. Drill-down**
- 3. Dice**
- 4. Slice**
- 5. Pivot**

Les Operations OLAP

Roll-up et drill-down

Un roll-up sert à changer le niveau de détail pour une des dimensions d'analyse, allant d'un niveau plus détaillé vers un niveau moins détaillé. On effectue un roll-up lorsqu'on souhaite obtenir moins de détails, ou qu'on souhaite obtenir une vue d'ensemble. On peut d'abord faire un roll-up a même une dimension qui dispose d'une hiérarchie. Prenons l'exemple des données suivantes :

France	3
Espagne	1
Suisse	41
Canada	24
É.-U.	14

La dimension **Lieu** est présentée a la granularité **Pays**. Si on juge que cela fournit trop de détails inutiles, on peut demander un roll-up vers le continent :

Europe	45
Amérique du Nord	38

Roll-up et drill-down

Dans cet exemple, nous utilisons la somme de la mesure pour effectuer l'agrégation, mais on pourrait tout aussi bien utiliser une autre opération comme la moyenne ou le maximum.

L'opération contraire, soit le passage des données portant sur les continents vers les données portant sur les pays, est un drill-down.

Une autre forme de roll-up ou de drill-down peut consister à faire disparaître ou apparaître une dimension au complet. Prenons l'exemple des pays et de leur mesure.

Roll-up et drill-down

Le **drill-down** est l'opération inverse du Roll-up. Imaginons que nous souhaitons décomposer les mesures selon une autre dimension, par exemple la **couleur** :

France	rouge	2
France	bleu	1
France	orange	0
Espagne	rouge	1
Espagne	bleu	0
Espagne	orange	0
Suisse	rouge	40
Suisse	bleu	1
Suisse	orange	0
Canada	rouge	20
Canada	bleu	4
Canada	orange	0
É.-U.	rouge	10
É.-U.	bleu	4
É.-U.	orange	0

Cette nouvelle table représente un drill-down par rapport à la table originale, **parce qu'il y a plus de détails. L'opération inverse, celle qui consiste à faire disparaître l'attribut couleur, est un roll-up.**

Il est important d'observer que lorsque l'on fait un drill-down ou un roll-up, les mesures sont modifiées en conséquence. Ainsi, si on fait la somme des mesures, et qu'il ne s'agit que de mesures positives, un roll-up va toujours générer des valeurs de mesures plus importantes. Au contraire, le drill-down réduira la valeur des mesures.

Dice

Une opération de type dice consiste a générer une nouvelle table, qui comporte autant de dimensions et les mêmes valeurs de mesures, mais ou l'on restreint certaines des dimensions a quelques mesures.

Prenons l'exemple de la table précédente, qui comprend a la fois des **pays** et des **couleurs**. Imaginons que nous voulions éliminer la couleur orange et ne conserver que les pays européens :

France	rouge	2
France	bleu	1
Espagne	rouge	1
Espagne	bleu	0
Suisse	rouge	40
Suisse	bleu	1

Le résultat est un dice. Contrairement au drill-down et au roll-up, lorsque l'on effectue un dice, les valeurs ne sont pas modifiées et l'on conserve les mêmes dimensions et les mêmes valeurs. On se contente d'éliminer certaines des valeurs indésirables.

Dice

Si on représente nos données selon deux axes, un pour chaque dimensions, on constate qu'on peut illustrer le dice comme la sélection d'un sous-ensemble des mesures :

France	rouge	2
France	bleu	1
Espagne	rouge	1
Espagne	bleu	0
Suisse	rouge	40
Suisse	bleu	1



	rouge	bleu	orange
France	X	X	
Espagne	X	X	
Suisse	X	X	
Canada			
É.-U.			

Cette illustration explique le terme dice : on a coupe et extrait un sous-cube.

Slice

L'opération **roll-up** *peut réduire le nombre de dimensions, mais les mesures sont modifiées de manière correspondante.*

*L'opération **dice** préserve les valeurs des mesures, mais omet une partie des données.*

L'opération **slice**, quant à elle, réduit le nombre de dimensions (comme une opération roll-up) mais, tout comme l'opération dice, elle laisse les valeurs de mesures inchangées, se contentant d'omettre une partie des données.

Slice

Imaginons que dans l'exemple des pays et des couleurs, nous nous intéressions qu'à la couleur rouge. Dans un tel cas, nous pourrions extraire les enregistrements correspondants dans la table de faits :

France	rouge	2
Espagne	rouge	1
Suisse	rouge	40
Canada	rouge	20
É.-U.	rouge	10

On se rend compte, par contre, que **de conserver la dimension couleur ne sert pas à grand chose**. Il vaut mieux l'omettre :

France	2
Espagne	1
Suisse	40
Canada	20
É.-U.	10

Si on représente nos données selon deux axes, on voit que l'opération slice correspond à une tranche.

Slice

Si on représente nos données selon deux axes, on voit que l'opération slice correspond a une tranche :

France	2
Espagne	1
Suisse	40
Canada	20
É.-U.	10



	rouge	bleu	orange
France	X		
Espagne	X		
Suisse	X		
Canada	X		
É.-U.	X		


Pivot

Le pivot peut designer l'opération triviale qui consiste a permuter les axes dans une représentation bidimensionnelle des données. Par exemple, on pourrait échanger les dimensions **couleurs** et **pays**.


Le pivot peut aussi correspondre au remplacement d'un roll-up par un autre. Imaginons que vous ayez une table de faits ayant **les dimensions pays, couleur et mois**. Après un roll-up sur la dimension mois, vous obtenez une vue comportant les dimensions pays et couleur. Vous pourriez alors souhaiter passer de ce roll-up a un roll up sur la dimension pays ou couleur, générant respectivement une vue comportant les dimensions couleur et mois puis couleur et mois.

On peut expliquer le terme pivot en imaginant un cube en trois dimensions que l'on fait tourner afin d'en consulter les différentes faces.


Roll UP




Drill Down



Drilldown on
time(from
quarters to month)




Dice



Dice for (location="Toronto" or "Vancouver")
and (time="Q1" or "Q2") and
(item="Mobile" or "Modem")




Slice



Locations
(cities)



Chicago				
New York				
Toronto				
Vancouver	605	825	14	400
	Mobile	Modem	Phone	Security
	item (types)			

Pivot



Item
(types)

Mobile				605
Modem				825
Phone				14
Security				400
	Chicago	New York	Toronto	Vancouver
	Location (cities)			



Les Outils OLAP

- Les outils relationnels OLAP (ROLAP)
 - Les données sont stockées dans une base de données relationnelle, moteur OLAP permet de simuler le comportement d'un SGBD multidimensionnel
 - .
- Les outils MOLAP
 - Utilisent un système multidimensionnel « pur » qui gère les structures multidimensionnelles natives (les cubes)
 - Accès direct aux données dans le cube
- Les outils HOLAP (Hybrid OLAP)
 - tables de faits et tables de dimensions stockées dans SGBD relationnel (données de base)
 - données agrégées stockées dans des cubes

Les différents modes de stockage OLAP

MOLAP (Multidimensional OLAP), est une solution de stockage qui garantit les temps de réponses, mais se traduit par des temps d'alimentation et de stockage plus importants.

ROLAP (Relational OLAP) stocke les données dans une base de données relationnelle, mais détériore les temps de réponse, puisque les calculs sont effectués en dynamique lors de l'analyse. Le stockage est optimisé et laisse une plus grande liberté de requête.

Les plateformes décisionnelles évoluées permettent aujourd'hui une solution de continuité entre ces choix, en prévoyant notamment un choix hybride (**HOLAP**) où seule une partie des données sont pré-calculées et stockées.

OLTP et OLAP

Le terme OLTP On Line Transaction Processus regroupe les concepts mis en place par un système destiné à l'automatisation d'un processus. On utilise pour cela une base de données transactionnelles, dont la mise à jour est faite en ligne.

Le terme OLAP On Line Analysis Processus regroupe les concepts mis en place par un système d'analyse en ligne des données. On utilise pour cela une base de données décisionnelles, destinée à la prise de décision.

Les OLTP et OLAP deux systèmes diffèrent pour :

- les utilisateurs ;
- le contenu des données ;
- la structure de la base de données ;
- l'administration du système.

OLTP et OLAP

OLTP	OLAP
<i>Utilisateurs</i>	
Les utilisateurs sont les rouages de l'entreprise	Les utilisateurs observent les rouages de l'entreprise
Beaucoup d'utilisateurs concurrents	Peu d'utilisateurs (décideurs)
Une seule vision métier	Traite plusieurs visions métier
Exécutent un grand nombre de fois la même tâche	Lisent uniquement les données qui sont souvent récapitulées.
Lisent et modifient les données (système vivant)	Les demandes sont similaires mais différentes.
Exigent des performances (temps réel pour augmenter la productivité) ERP, GPAO, RH...	

OLTP et OLAP

OLTP	OLAP
<i>Contenu des données</i>	
Nécessaire au fonctionnement de l'entreprise	Utilisé pour analyser le fonctionnement de l'entreprise.
Normalisation en 3FN	Agrégée (dénormalisée)
Non historisé	Le temps est fondamental
<i>Structures</i>	
Beaucoup de tables	Peu de tables mais de grande taille
Petites requêtes sur une seule table	Requêtes larges sur une grosse quantité de données
Temps de réponses instantanés (temps réel)	Temps de réponse de quelques secondes à plusieurs minutes.
<i>Administration</i>	
Forte disponibilité	Disponibilité faible
Sauvegardes fréquentes	Sauvegardes peu fréquentes, mais très volumineuses.
Beaucoup de petites transactions	En règle générale, une transaction par jour.
Peu de maintenance off-line	Beaucoup de maintenance off-line

Online Analytical Processing (OLAP)

Traitement analytique en ligne (OLAP)

OLAP se caractérise par un volume de transactions relativement faible. Les requêtes sont souvent très complexes et impliquent des agrégations. Pour les systèmes OLAP, le temps de réponse est une mesure d'efficacité. Les applications OLAP sont largement utilisées par les techniques de Data Mining. Les bases de données OLAP stockent des données historiques agrégées dans des schémas multidimensionnels (généralement des schémas en étoile). Les systèmes OLAP ont généralement une latence des données de quelques heures, contrairement aux data marts, où la latence est censée être plus proche d'une journée. **L'approche OLAP est utilisée pour analyser des données multidimensionnelles provenant de plusieurs sources et perspectives.**

Les opérations de base dans OLAP sont : **Roll-up** (Consolidation), **Drill-down** et **Slicing et Dicing**.

Online Transaction Processing (OLTP)

Traitement des transactions en ligne (OLTP) OLTP se caractérise par un grand nombre de transactions en ligne courtes (INSERT, UPDATE, DELETE). Les systèmes OLTP mettent l'accent sur le traitement très rapide des requêtes et le maintien de l'intégrité des données dans les environnements multi-accès. Pour les systèmes OLTP, l'efficacité est mesurée par le nombre de transactions par seconde. Les bases de données OLTP contiennent des données détaillées et actuelles. Le schéma utilisé pour stocker les bases de données transactionnelles est le modèle d'entité (généralement 3NF). La normalisation est la norme pour les techniques de modélisation des données dans ce système.

Software Tools ou Outils logiciels

L'entrepôt de données typique basé sur l'extraction-transformation-chargement (ETL) utilise des couches de transfert (staging), d'intégration de données et d'accès pour héberger ses fonctions clés.

La couche intermédiaire ou la base de données intermédiaire (The staging layer or staging database) stocke les données brutes extraites de chacun des systèmes de données sources disparates. **La couche d'intégration intègre** les ensembles de données disparates en transformant les données de la couche intermédiaire en stockant souvent ces données transformées dans une **base de données de stockage de données opérationnelles (ODS)**. *Les données intégrées sont ensuite déplacées vers une autre base de données, souvent appelée base de données d'entrepôt de données, où les données sont organisées en groupes hiérarchiques souvent appelés dimensions et en faits et faits agrégés.* La combinaison de faits et de dimensions est parfois appelée schéma en étoile. La couche d'accès aide les utilisateurs à récupérer les données.

Modélisation et Conception d'un DW

Construction d'un Data warehouse

Caractéristiques du DW

- Le Data warehouse est différent des bases de données de production:
 - Les besoins pour lesquels on veut le construire sont différents
 - Il contient des informations historisées, organisées selon les métiers de l'entreprise pour le processus d'aide à décision
- Le Data warehouse n'est pas un produit ou un logiciel mais un environnement, qui se bâtit et ne s'achète pas.

Modélisation et Conception d'un DW

Les phases de construction d'un DW

La construction d'un Data warehouse est composée de trois parties interdépendantes qui sont:

- 1. L'étude préalable** qui va définir les objectifs, la démarche à suivre, le retour sur investissement,...
- 2. L'étude du modèle de données** qui représente le DW conceptuellement et logiquement
- 3. L'étude de l'alimentation du Datawarehouse**

Etude Préalable

❑ Etude des besoins:

- Définir les objectifs du DW
- Déterminer le contenu du DW et son organisation, d'après:
 - Les résultats attendus par les utilisateurs,
 - Les requêtes qu'ils formuleront,
 - Les projets qui ont été définie
- Recenser les données nécessaires à un bon fonctionnement du DW:
 - Recenser les données disponibles dans les bases de production
 - Identifier les données supplémentaires requises
- Choisir les dimensions
 - Typiquement: le temps, le client, le produit, le magasin...
- Choisir les mesures de fait
 - De préférences de quantités numériques additives
- Choisir la granularité des faits
 - Niveau de détails des dimensions

Etude Préalable

❑ Coûts de déploiement:

- **Nécessite des machines puissantes, souvent une machine parallèle**
- **Capacité de stockage très importante (historisation des données)**
 - Evaluer la capacité de stockage
- **Equipes de maintenance et d'administration**
- **Les coûts des logiciels**
 - Les logiciels d'administration du DW
 - Les outils ETL (Extract-Transform- Loading)
 - Les outils d'interrogation et de visualisation
 - Les outils de Datamining

Modélisation

- **Niveau conceptuel:**

- Un DW est basé sur une modélisation multidimensionnelle qui représente les données dans un cube
- Un cube permet de voir les données suivant plusieurs dimensions:
 - ✓ Tables de dimensions
 - ✓ La table des faits contient les mesures et les clés des dimensions

- **Niveau Logique:**


- Plusieurs schémas types sont proposés pour représenter un DW:
 - ✓ Schéma en étoile;
 - ✓ Schéma en flocon;

- **Schéma en étoile**

- Une (ou plusieurs) table(s) de faits : identifiants des tables de dimension ; une ou plusieurs mesures.
- Plusieurs tables de dimension : descripteurs des dimensions.

Modélisation


- Schéma en étoile



Modélisation

○ Schéma en flocons

- Raffinement du schéma étoile avec des tables normalisées par dimensions.




Alimentation

- L'alimentation est la procédure qui permet de transférer des données du système opérationnel vers le DW
- La conception de cette opération est une tâche complexe
 - 60 à 90 % de la charge totale d'un projet DW
- Elle doit être faite en collaboration avec l'administrateur des bases de productions
- Il est nécessaire de déterminer:
 - Quelles données seront chargées
 - transformations et les vérifications nécessaires
 - La périodicité et le moment de transferts des données

Alimentation

Alimentation d'un DW (ETL)

- Extraction (Extract)
- Transformation (Transform)
 - Filtrer
 - Homogénéiser
 - Nettoyer
 - Etc ...
- Chargement (Loading)



Alimentation

Extraction:

- Depuis les bases sources
- Périodique et Répétée
- Dater ou marquer les données envoyées
- Difficulté:
 - Ne pas perturber les applications OLTP
- Différentes techniques d'extraction:
 - Méthode Push: Le système opérationnel qui au fil des transactions alimente le DW
 - Méthode Pull : Le système décisionnel cherche périodiquement les données dans les bases de production

Alimentation

Transformation

- C'est une suite d'opérations qui a pour but de rendre les données cibles homogènes et puissent être traitées de façon cohérente.
 - Unification des modèles
 - Convertir / uniformiser les noms des attributs
 - Uniformiser les valeurs d 'attributs
 - Nettoyer (Valeurs manquantes, aberrantes...)

Alimentation

Chargement

- C'est l'opération qui consiste à charger les données nettoyées et préparées dans le DW.
- C'est une opération qui peut être longue :
 - Mettre en place des stratégies pour assurer de bonnes conditions à sa réalisation
 - Définir la politique de rafraîchissement.
- C'est une phase plutôt mécanique et la moins complexe

Outils ETL

- ❑ BusinessObjects, Data Integrator,
- ❑ Oracle Corporation, Warehouse builder,
- ❑ IBM, Websphere Datastage,

Exercice 1

Il s'agit de modéliser le Data warehouse des ventes d'une entreprise commerciale. Cette entreprise vend **des produits regroupés par familles de produits**. Une vente correspond à un produit et un seul; la vente est effectuée par l'un des vendeurs du service de vente spécialisé dans le produit. Le Data warehouse doit pouvoir fournir le chiffre d'affaires des ventes d'un produit, par date, client, et vendeur, ainsi que toutes les sommes possibles de chiffre d'affaires.


- **produit**, caractérisé par : code_produit, code_famille, etc...
- **client**, caractérisé par : code_client, nom, CSP (catégorie socio-professionnelle), etc ...
- **vente**, caractérisée par : code_date, code_produit, code_client, code_vendeur, Chiffre d'affaires
- **vendeur**, caractérisé par : code_vendeur, nom, code_service, etc...
- **date**, caractérisée par : code_dat, semaine, mois, année, etc...

Exercice 1 (suite)

Travail à faire :

1. Donner les définitions des termes suivants :un fait, une dimension, la table de faits, la table de dimension, et hiérarchie.
2. Tracer le schéma en étoile dimensionnel du Data warehouse, en précisant pour chaque table sa nature dimensionnelle (table de faits ou table de dimension), ses clés, ainsi que la nature des champs.

Solution



Exercice 3

Un distributeur (grossiste) approvisionne plusieurs magasins en produits, en effectuant au plus une livraison par jour et par magasin. Les informations qui figurent sur chaque bon de livraison sont les suivantes : le numéro du bon de livraison, la date de livraison, la référence du magasin, et pour chaque type de produit livré sa référence et la quantité livrée (le nombre d'articles). Ces informations sont stockées chez le distributeur, et accumulées pendant des longues périodes afin de les analyser pour améliorer le service de distribution. Les analyses se font suivant plusieurs axes, et à plusieurs niveaux, en analysant les mouvements des produits par jour et par mois, par ville et par région, par fournisseur et par catégorie de produit.

On supposera qu'un fournisseur peut fournir au distributeur des produits dans plusieurs catégories et qu'une catégorie de produit peut être fournie par plusieurs fournisseurs.

Définir le schéma dimensionnel du Data warehouse permettant d'analyser la quantité livrée par ville et catégorie de produits, en faisant apparaître clairement les dimensions et les indicateurs.

Exercice 2

Une université cherche à étudier les facteurs influant sur la réussite de ses étudiants aux examens. Pour cela elle décide de construire un Data warehouse. Elle souhaite pouvoir répondre aux questions suivantes:

- Quel est le nombre de réussites aux examens par cours, pour l'année 2007?
- Quel est le nombre de réussites aux examens d'un cours obligatoire, pour l'année 2007?
- Quel est le nombre de réussites aux examens par sexe (féminin, masculin), pour l'année 2007?
- Combien d'étudiants ayant un âge de 22 ans ont réussi leurs examens de base de données relationnelle?
- Quel est le nombre de réussites aux examens pendant le semestre d'hiver 2006?

Pour cela elle dispose des données suivantes: Pour chaque examen passé, on connaît l'âge et le sexe de l'étudiant, le nom du cours (les cours peuvent être regroupés en cours obligatoire et cours à option), la date de l'examen, la note obtenue et si l'examen est réussi ou non.

Travail à faire :

1. Recherchez tout d'abord les différentes dimensions et proposez une hiérarchie pour ces dimensions.
2. Proposez un modèle en étoile pour cette application.

Exercice 4

On veut construire un entrepôt de données afin de stocker les informations sur les consultations d'un pays. On veut notamment connaître le nombre de consultations, par rapport à différents critères (personnes, médecins, spécialités, etc). Ces informations sont stockées dans les relations suivantes :

PERSONNE (id, nom, tel, adresse, sexe)

MEDECIN (id, tel, adresse, spécialité)


CONSULTATION (id_med, id_pers, date, prix)

Travail à faire :

1. Proposer un schéma relationnel qui tient compte **de la date, du jour de la semaine, du mois, du trimestre et de l'année**.
2. Quelle est la table des faits?
3. Quels sont les faits?
4. Combien de dimensions ont été retenues? Quelles sont-elles?
5. Quelles sont les hiérarchies des dimensions? Dessinez les.

Solution 4

1. Proposer un schéma relationnel qui tient compte de la date, du jour de la semaine, du mois, du trimestre et de l'année.



2. Quelle est la table des faits?

Consultation

3. Quels sont les faits?

Le prix et **le nombre de consultations** (nb_consult)

4. Combien de dimensions ont été retenues? Quelles sont-elles?


Trois dimensions : Médecin, Personne, Temps

5. Quelles sont les hiérarchies des dimensions? Dessinez les.

Année → Trimestre → Mois → JourSemaine → Date

Solution 4

6. Faites une représentation du cube OLAP sans tenir compte des hiérarchies



7. A partir de ce cube, indiquez quelles opérations OLAP (roll up, drill down, slice, dice) il faut appliquer pour obtenir les informations suivantes :

a. le coût total des consultations par médecin en 2012 et 2013

(On fait deux requêtes, une pour chaque année)

Roll-up on temps to Année

Slice Année = 2012

Roll-up on temps to Année

Slice Année = 2013

(Cout « total », donc Slice avec une opération d'agrégation)

Solution 4

b. le nombre de consultations par jour de la semaine, par spécialité et par sexe du patient

Roll up on Date to jourSemaine

Roll-up on Médecin to spécialité

Roll-up on Personne to sexe

c. le coût des consultations par patiente pour les mois d'octobre

Roll-up on Date to mois

Dice mois = octobre (Coût des consultations, donc Dice sans une opération d'agrégation)

Exercice 5


On dispose d'un outil OLAP pour analyser les salaires selon l'âge et le niveau d'étude des personnes et la situation géographique des entreprises. L'analyse selon l'âge peut se faire par année ou par décade (tranches de 10 années à partir de 14 ans et jusqu'à 73 ans). L'analyse du niveau d'étude peut se faire par le niveau d'enseignement atteint en fin d'études (primaire, secondaire, supérieur) ou par le dernier diplôme obtenu (certificat de fin d'étude primaire, BEPC, Bac, Licence, Master). L'analyse de la situation géographique peut se faire par ville, région ou pays.

Travail à faire :

1. Proposer un schéma relationnel pour cette analyse qui tient compte de la ville, du département, de la région et du pays?
2. Quelle est la table des faits?
3. Quels sont les faits?
4. Combien de dimensions ont été retenues? Quelles sont-elles?
5. Quelles sont les hiérarchies des dimensions? Dessinez les.

Solution 5

1. Proposer un schéma relationnel pour cette analyse qui tient compte de la ville, de la région et du pays?



2. Quelle est la table des faits?

Salarié

3. Quels sont les faits?

Un seul fait : salaire

4. Combien de dimensions ont été retenues? Quelles sont-elles?

Trois dimensions : Ville, Etude et Age

5. Quelles sont les hiérarchies des dimensions? Dessinez les.

Pays → Région → Ville

Exercice 6

Mr Bertrand directeur d'une entreprise de la grande distribution souhaite analyser et suivre les ventes de produits dans son réseau de magasins. Mr Bertrand souhaite obtenir une réponse aux questions suivantes:

- Quels produits dégagent la plus forte rentabilité dans le temps?
- Existe-t-il des disparités régionales de consommation des produits?
- Quel est la répartition des ventes entre les produits de marque des fabricants et ceux de la marque du distributeur?
- Quel est le chiffre d'affaire réalisé avec les plus gros fournisseurs?

L'ensemble des informations seront issues des tickets de caisse.

Exercice 6 (suite)

Nous identifions un certain nombre d'axes d'analyse: l'axe produit, l'axe magasin, l'axe temps, l'axe localité, l'axe fournisseur.

Il faut ensuite décrire la hiérarchie de chacun de ces axes:

- pour l'axe produit : un produit appartient à une sous-famille de produits, laquelle appartient à une famille de produits, laquelle appartient à une gamme de produit. -

Pour l'axe magasin: un magasin est rattaché à une enseigne.

- Pour l'axe fournisseur: un fournisseur appartient à un groupe de fournisseurs.
- Pour l'axe localité: un département est rattaché à une région, laquelle est rattachée à un pays.
- Pour l'axe temps: un mois est rattaché à un trimestre qui est rattaché à un semestre qui est rattaché à une année.

On cherche alors à décrire les indicateurs suivants: les ventes par produit, par magasin par fournisseur, par région et dans le temps. Proposer un schéma en étoile et en flocon pour ce cas.

Exercice 7

Un chef d'un grand groupe regroupant plusieurs compagnies situées dans plusieurs pays souhaite réaliser une étude sur ses employés. Pour cela il a à sa disposition les données du service des ressources humaines sur les employés. Voici quelles sont les données à sa disposition et comment est organisée l'entreprise: Pour chaque employé on mémorise dans le SI son nom, sa date de naissance, son sexe et sa situation familiale (marié, concubinage, pacs, célibataire, veuf, divorcé). Lorsqu'il est engagé dans le groupe chaque employé se voit attribuer un numéro d'employé, il est affecté dans un service d'une compagnie du groupe. On enregistre sa date d'engagement. Un employé est engagé avec un type de contrat particulier qui peut être un CDD (contrat à durée déterminée) ou un CDI (contrat à durée indéterminée).

Exercice 7 (suite)

Chaque employé est engagé à un grade particulier qui caractérise son niveau d'avancement dans l'entreprise; ce grade peut évoluer au cours de sa carrière. Les grades vont de 1 à 25. Un employé devient cadre lorsque son grade est supérieur à 20. Chaque année les employés peuvent recevoir une prime de performance plus ou moins importante selon le travail qu'ils ont effectué.

Le décideur de ce groupe souhaite analyser un certain nombre de variables de l'entreprise:

- Le nombre d'employés
- Le % d'employés (nombre d'employé considéré / nombre total d'employé)
- Le salaire moyen - Le taux d'occupation moyen
- -Le nombre de jours d'absence - Les primes de performance moyennes

Exercice 7 (suite)

Il souhaite analyser ces variables en fonction de plusieurs paramètres: le numéro d'employé, le type de contrat, le sexe, l'âge, le grade, la situation familiale, l'ancienneté. Il souhaite pouvoir répondre aux questions suivantes:

- Quelles pays et quelles compagnies ont le plus d'employés, les plus haut salaires ... ?
- Quel était le nombre d'employé de la compagnie X au premier trimestre de 2004 ?
- Quel était le taux d'occupation moyen par service en 2003 ?
- Quel est le profil (sexe, âge, grade) des employés les plus "dynamiques" ?
- Y a-t-il un rapport entre l'ancienneté des employés et leur performance ?
- Quels sont les mois de l'année où les employés sont les plus absents ?

Exercice 7 (suite)

Travail A faire :

- 1) Rechercher tout d'abord les différentes dimensions et proposer éventuellement une hiérarchie pour ces dimensions (certaines dimensions n'auront pas de hiérarchie). Exemple: Pour la dimension âge, on peut regrouper l'âge par groupe d'âges (20-30 ans, 30-40,...).
- 2) Pour chaque mesure, vous devez préciser pour chaque dimension quel type d'agrégation sera faite lors du passage d'une granularité à une autre. Exemple: Pour la mesure salaire, pour la dimension organisation, on fera une moyenne du salaire de chaque employé.
- 3) Proposer un modèle en étoile pour cette application.

Exercice 8

Une compagnie d'assurance de biens (automobile, immobilier, responsabilité civile) possède une application transactionnelle de production qui permet de gérer les polices (contrats) de ses clients ainsi que les sinistres (accidents) déclarés par ces clients.

Exercice 8 (suite)

1. Gestion des polices Pour gérer les polices, les employés ou agents d'assurance externes à la compagnie peuvent effectuer les transactions suivantes :

- Créer, mettre à jour ou supprimer une police d'assurance
- Créer, mettre à jour ou supprimer un risque (pour une police donnée)
- Créer, mettre à jour ou supprimer des biens assurés (voiture, maison) sur un risque
- Chiffrer ou refuser le risque
- Valider ou refuser la police

On enregistre dans ces transactions un grand nombre d'informations, et notamment : **date d'écriture** (date de la transaction), **date d'effet** (date de début d'assurance), **client** (personne(s) privée(s), personne morale), **opérateur** (employé, agent : chiffrage, vérificateur : validation), **risque** (produit vendu par la compagnie d'assurance), **couverture** (description des biens assurés), **police** (numéro de police, « note » de la police ou du risque, ...) , transaction (code transaction).

Exercice 8 (suite)

2. Gestion des sinistres

Pour gérer les sinistres déclarés par les clients, les employés ou agents d'assurance ont à leur disposition les transactions suivantes :

- Créer, mettre à jour ou supprimer une déclaration de sinistre
- Créer, mettre à jour ou supprimer une expertise
- Créer, mettre à jour ou supprimer des paiements
- Clore le sinistre

Ces transactions comportent notamment : date d'écriture (date de la transaction), date d'effet (date de déclaration), client, opérateur, risque, biens sinistrés, police, les tiers impliqués dans le sinistre, les montants financiers (limites, déjà payé, reste à payer, ...), code transaction.

Exercice 8 (suite)

3. Taille des bases de données

- Nombre de polices : 2 millions
- Moyenne de biens couverts par police : 10
- Nombre de transactions par an et par police : 12
- Nombre d'années : 3
- Taille d'une variable (clé ou indicateur) de table de faits : 8 octets
- Pourcentage de biens assurés donnant lieu à un sinistre par an : 5%
- Temps d'ouverture d'un sinistre : 1 an

Exercice 9

Le Ministère de la Santé et du Bien-Etre de Groland veut construire un entrepôt de données afin de stocker les informations sur les consultations d'un pays. On veut notamment connaître le nombre de consultations, par rapport à différents critères (personnes, médecins, spécialités, etc). Ces informations sont stockées dans les relations suivantes :

PERSONNE (id, nom, tel, adresse, sexe)

MEDECIN (id, tel, adresse, spécialité)

CONSULTATION (id_med, id_pers, date, prix)

Question 1 :

Proposer un schéma en étoile et les tables relationnelles correspondantes qui tient compte de la date, du jour de la semaine, du mois, du trimestre et de l'année. Représenter le cube OLAP.

Question 2 :

A partir de ce cube, indiquez quelles opérations OLAP (roll up, drill down, slice, dice) il faut appliquer pour obtenir les informations suivantes :

- a) le coût total des consultations par médecin en 2005
- b) le nombre de consultations par jour de la semaine, par spécialité et par sexe du patient
- c) le coût des consultations par patiente pour les mois d'octobre

Questions

A partir de cette application transactionnelle, on veut créer un entrepôt de données permettant de répondre aux questions suivantes :

- on ne s'intéresse qu'à la globalisation par mois des transactions.
- pour chaque bien assuré, on veut connaître le montant de la prime (somme annuelle payée par le client pour assurer le bien) associée au bien assuré, et le nombre de transactions du mois pour ce bien.
- On veut aussi l'« état » de la police pour en spécifier les phases particulières : police nouvellement créée, nouvellement modifiée, sinistre en cours, sinistre juste clos.
- On veut naturellement sortir des tableaux par client, agent ou employé, date d'effet, état, avec toutes les sommations possibles y compris par police et risque.
- De même on veut pouvoir sortir des tableaux de bord par sinistre avec le total payé dans le mois et le total reçu dans le mois pour ce sinistre.

Les tableaux de bord « sinistre » doivent pouvoir être édités par client, agent ou employé, date d'effet, état, avec toutes les sommations possibles y compris par police et risque. On veut pouvoir établir des tableaux de bord par client et bien assuré de l'activité sur le dossier (nombre de transactions, nombre de sinistres), du chiffre d'affaire, du taux de sinistres et du rendement (ratio versements/prime), et tous les totaux et sous totaux correspondants.

- On veut également déterminer la taille sur disque de l'ED.

On suivra la démarche suivante :

1. commencer par tracer quelques tableaux de bord à titre d'exemple de ce que peut éditer l'ED : quelques (de l'ordre de 5) tableaux à deux dimensions pour les polices et quelques uns pour les sinistres (toujours à deux dimensions). Tracer au moins un cube à trois dimensions.
2. faire le schéma en étoile d'un magasin de données « police » ne prenant pas en compte les sinistres. Tracer au moins un cube à trois dimensions.
3. de même, faire le schéma en étoile d'un magasin « sinistre »
4. faire un seul ED de ces deux magasins. Y a-t-il des dimensions conformes ? Quels tableaux de bord nouveaux peut-on alors éditer ?

Exercice 10

Le Ministère de la Santé et du Bien-Etre de Grolang vous sous-traite la réalisation d'un entrepôt de données pour réaliser des études sur les dépenses de santé dans son beau-pays, une autre société a déjà proposé un premier schéma. Les bases de production de cet entrepôt sont les systèmes d'information des centres de sécurité sociale et des assurances santé complémentaire de Groland qui gèrent les dossiers (électroniques) des assurés. Le schéma de l'entrepôt est constitué des tables suivantes (les clés primaires sont soulignées)

Date(CléDate, Année, Mois, JourDeMois, JourDeSemaine, TrancheHoraire, DrapeauVacances)

Assuré(CléAssuré, MoisNaissance, AnnéeNaissance, MoisDécès, AnnéeDécès, Région, Département, District, Ville, Quartier, RevenuAssuré, RevenuFoyer, CatégorieSocioProfessionnel, SousCatégorieSocioProfessionnel, DomaineActivité, CaissePrimaire, CaisseComplémentaire, DrapeauAssuréPrincipal)

Patricien(CléPraticien, Spécialité, SousSpécialité, Région, Département, District, Ville, Quartier, MoisNaissance, AnnéeNaissance, DrapeauConventionné)

Exercice 10 (suite)

Pathologie(CléPathologie,DesignationNormalisé,Spécialité,SousSpécialité,
TauxDIncapacité, DuréeTraitement, Chronicité, DrapeauMaladieProfessionnelle)

Rétro-Conception

Quelle est la table de fait dans cet entrepôt ? A votre avis, y-a-t'il des dimensions douteuses dans cet entrepôt ? Donnez les nouvelles tables si on décide de diminuer la taille de la table Assurée.

Dimensionnement

Donnez le nombre de faits présents dans la table de fait, la taille d'un enregistrement de la table de fait, et la taille (en Octets) de stockage de la table de fait.

Exercice 10 (suite)

- Nombre d'assurés : 60 Millions
- Nombre de actes par praticien et par jour : 20
- Un praticien travaille 300 jours par an
- Nombre de praticiens : 300 000
- Nombre d'actes supplémentaires prescrit par acte : 0,1
- Nombre d'années : 6
- Coûts annuel des actes : 180 Milliard d'Euro
- Taille des clés : 4 octets
- Taille des attributs numériques : 4 octets
- Taille des attributs booléens : 1 octet

Exercice 11


Une agence de voyage aimerait pouvoir analyser ses données afin de planifier de meilleures campagnes de promotion auprès de ses clients. Plus particulièrement, elle aimerait analyser le nombre et le montant des ventes en fonction:

- De la destination: hôtel, ville, pays, région, catégorie de région (ex: bord de mer, alpine, etc.), catégorie de destination (ex: familial ou non), catégorie hôtel (ex: 1- 4 étoiles) ;
- De la date d'achat: jour de l'année, jour de la semaine, mois, année, saison touristique (ex: basse ou haute saison);
- De la date de départ: jour de l'année, jour de la semaine, mois, année, saison touristique (ex: basse ou haute saison);
- Du forfait: nombre de personnes, nombre de nuits, type de forfait (ex: tout inclus, repas inclus, etc.), type de chambre (ex: standard, suite, penthouse, etc.) ;
- Du client: groupe d'âge, sexe, adresse, type d'acheteur (ex: nouveau, récurrent, etc.);
- Du canal de vente: catégorie (ex: magasin, internet, etc.) ;
- De la promotion: catégorie (ex: 2 pour 1, rabais 10%, rabais 25%, etc.), début et fin de validité ;
- Du mode de paiement: catégorie (ex: crédit, comptant, etc.) ;

Exercice 11 (suite)

- a) Proposez un schéma en étoile permettant de faire ces analyses. Identifiez clairement les clés primaires et étrangères des tables de faits et de dimension;
- b) Identifiez, pour chaque table de dimension, une hiérarchie de niveaux de granularité (e.g., attribut1 $\leftarrow$ attribut2 $\leftarrow$...);

Exercice 12 (suite)



Exercice 12 (suite)

La plupart des attributs dimensionnels ont un ID ainsi qu'un champ descriptif. Par exemple, dans la table **Date**, le mot 'Novembre' n'est pas suffisant pour identifier avec précision ce mois, car on le retrouve dans chacune des années. Il faut donc un attribut **idMois** (ex: '11/2010') ainsi qu'un attribut descriptif **descrMois** (ex: 'Novembre'). C'est la même chose pour l'attribut ville: le même **nom de ville peut se trouver dans plusieurs pays** ou même plusieurs fois dans un même pays; Nous avons créé une table TypeClient selon la stratégie de mini-dimension. L'avantage est que la table TypeClient peut être pré-générée (toutes les combinaisons possibles de sexe, ville, groupe d'âge, etc.). De même, les tables Destination, Date, Forfait, Promotion et