

II. Modélisation et implantation d'un entrepôt de données

- **Modélisation multidimensionnelle**
- **De la table au cube**
- **Stratégies d'implantation**
- **Schéma en étoile, en flocon et en constellation**

Modélisation multidimensionnelle (1)

- Les analyses décisionnelles (**OLAP**) sont directement reliées à une modélisation de l'information spécifique :

- § **proche de la perception qu'en a l'analyste**

- § basée sur une **vision multidimensionnelle des données**

- **Modélisation « multidimensionnelle » :**

- § considère un sujet analysé comme un **point dans un espace** à plusieurs dimensions

- § les **données y sont organisées** de façon à **mettre en évidence le sujet analysé** et les différentes perspectives de l'analyse.

Modelisation multidimensionnelle (2)


Soit les données relatives aux ventes de 1999 d'une entreprise de distribution :

Categorie des produits	Region	Montant des ventes
Electromenager	Midi-Pyrenees	50
Electromenager	Aquitaire	40
Electromenager	Languedoc-Rossillion	30
Papeterie	Midi-Pyrenees	60
Papeterie	Languedoc-Rossillion	50
Bricolage	Midi-Pyrenees	30
Bricolage	Aquitaire	30

Modélisation multidimensionnelle (3)

Différentes perspectives pour observer ces données :

- une dimension relative à la **catégorie des produits**
- une dimension relative à la **région**




Modelisation multidimensionnelle: concept de fait

Un fait :

- modélise le **sujet** de l'analyse
- est formé de **mesures** correspondant aux informations de l'activité analysée.
- ces mesures sont **numériques** et généralement **valorisées de façon continue**, on peut les **additionner**, les **dénombrer** ou bien **calculer** le minimum, le maximum ou la moyenne.

Exemple : le fait de « Vente » peut être constitué des mesures d'activités suivantes :

- quantité de produits vendus et
- montant total des ventes




Modélisation multidimensionnelle: concept de dimension

Le sujet analysé, le fait, est analysé suivant différentes perspectives ou axes caractérisant ses mesures de l'activité : on parle de dimensions.

Une **dimension** :

- modélise un axe d'analyse
- se compose de paramètres correspondant aux informations faisant varier les mesures de l'activité.

Ex: Dans l'exemple précédent, le fait « *Vente* » peut être analysé suivant différentes perspectives correspondant à trois dimensions : la dimension *Temps*, la dimension *Géographie* et la dimension *Catégorie* :



Modélisation multidimensionnelle: hiérarchie de dimension

- Les faits sont analysées selon les dimensions qui les caractérisent
- Nécessaire de définir pour chaque dimension ses différents niveaux hiérarchiques de détail (d'agrégation),
- Les **hiérarchies** de dimensions définissent des niveaux de détail de l'analyse sur les dimensions

Ex:

- **Dimension « temps » :**
 - H1 : jour -> mois -> année ;
 - H2 : jour -> mois -> trimestre -> année ;
 - H3 : jour -> mois -> saison -> année ;
- **Dimension « géographie » :** ville -> département -> région (chaque ville appartient à un département qui est situé dans une région)
- **Dimension « catégorie » :** couleur -> nomProduit -> gamme -> typeProduit (chaque produit appartient à une gamme de produit qui appartient à un type de produit)

De la Table au Cube

De la table ...


Table Ventes :

VENTES	pièces	Régions	Années	quantités
	écrous	est	1999	50
	clous	est	1997	100
	vis	ouest	1998	50
	...	...	...	...
	écrous	est	total	220
	...	...	...	...
	écrous	total	total	390
	...	...	...	...
	total	total	total	1200

(pièce, région, année) □ quantité

... au cube

Cube Ventes :



Stratégies d'implantation d'un ED

3 stratégies :

1 - Usage d'un SGBD Relationnel (systèmes ROLAP)

§ les **SGBDR** représentant **plus de 80% des SGBD** : ils sont principalement envisagés pour le développement d'ED mais doivent être adaptés

§ Ils doivent cependant **être adaptés** car ils n'ont pas les caractéristiques adéquates pour répondre aux besoins des ED.

2 - Usage d'un SGBD Multidimensionnel (systèmes MOLAP)

§ Un SGBD Multidimensionnel (SGBDM) est **un SGBD capable de stocker et** traiter des données multidimensionnelles

§ A ce jour **pas encore de cadre technologique commun** pour le développement de tels systèmes : chaque produit est spécifique

3 - Usage d'un SGBD Hybride (systèmes HOLAP)

Tire profit des avantages des technologies ROLAP et MOLAP :

§ un **ROLAP** pour stocker, gérer les *données détaillées ET*

§ un **MOLAP** pour stocker, gérer les *données agrégées*

Schema d'un Entrepot de donnees

Niveau logique « ROLAP » :

3 grands types de schémas :

- schéma en **étoile** (star schema)
- schéma en **flocon** (snowflake schema)
- schéma en **constellation** (fact constellation)

==> le schéma en **étoile** est souvent utilisé pour **l'implantation physique**

Schema en Etoile (1)

- **table des faits** : normalisée, de taille très importante, avec de nombreux champs
- **tables de dimensions** : dimensions de l'analyse, taille peu importante, avec peu de champs

Ex 1 : Vente de médicaments dans des pharmacies





Schéma en étoile modélisant les analyses des quantités et des montants des médicaments dans les pharmacies selon 3 dimensions : le temps, la catégorie et la situation géographique

- Table de **faits** : **Vente**
- Tables de **dimension** : **Temps, Catégorie, Géographie**

Schema en Etoile (2)

Ex 2 : Ventes d'articles dans un supermarché



Schema en Etoile (3)

Associé à Ex 2 :

- **un fait :**

- il a été acheté **3 exemplaires à 1 euro (SALE)**
- du **produit pid3**
- par le **client cid1**
- à la **date did3**
- dans le **magasin mid2** (store)
- dans le **chariot cid8** (basket)
- correspondant à la **promotion prid1**


- **un élément de la dimension location :**

- store id **mid2**
- store name **rondpoint**
- city **blois**
- region **centre**

Schema en flocon

Evolution du schéma en étoile avec une **décomposition des tables de dimensions** du modèle en étoile **selon leurs hiérarchies** (normalisation des tables de dimensions)

Ex 3: Vente de médicaments dans des pharmacies




Chaque dimension du schéma en étoile précédent est **dénormalisée**

Schema en constellation

- **fusionne plusieurs modèles** en étoile qui utilisent des dimensions communes.
- comprend en conséquence **plusieurs faits** et des **dimensions communes ou non**

Ex : Vente de médicaments dans des pharmacies



- une constellation est constituée de 2 schémas en étoile :

§ l'un correspond aux **VENTES** effectuées dans les pharmacies et

§ l'autre analyse les **PRESCRIPTIONS** des médecins

- les dimensions *Temps* et *Géographie* sont partagées par les faits **PRESCRIPTION** et **VENTE**.

III. Alimentation d'un Entrepot de donnees

§ Processus général d'alimentation d'un ED

§ Processus et outils ETL

§ Taches d'un processus ETL

Processus d'alimentation d'un ED (1)

- Le **processus d'alimentation d'un ED (ou entreposage des données)** consiste à :
 - § **rassembler** de multiples données sources souvent *hétérogènes*
 - § les **homogénéiser**
- **Homogénéisation** est faite selon des ***règles précises***
- **Ces règles :**
 - § sont mémorisées sous forme de **méta-données** (information sur les données) stockées dans le dictionnaire de données
 - § permettent d'assurer des **tâches d'administration** et de **gestion des données entreposées**.

Processus d'alimentation d'un ED (2)

Après avoir conçu le modèle des données, comment alimenter l'ED ?

→ **problématique de l'ETL (Extracting Transforming and Loading)**

4 étapes :

1. Sélection des données sources
2. Extraction des données
3. Nettoyage et Transformation
4. Chargement

Les Processus ETL (Extract Transform Load)

- Sont des **opérations de migration de données** pour les systèmes de Business Intelligence notamment les entrepôts de données
- Ils gèrent toutes les étapes de collecte et de transfert des données dans les ED :

§ **Extraction de données** des applications et des bases de données de gestion et de production (ERP, CRM, SGBDR, fichiers, etc.).

§ **Transformation de ces données** pour les consolider et les mettre en concordance.

§ **Chargement** : distribution des données auprès des applications cibles ou des systèmes décisionnels (Data Warehouse, Data Marts, applications OLAP ou “cubes”...).

- **Différents outils logiciels sont proposés :**

§ **Talend** : outils ETL en mode open source le plus connu

§ Autres solutions : **Apator**, **Jitterbit** et **Pentaho**.

Les Outils ETL (Extract Transform Load)

Ils permettent un support et/ou automatisation des tâches suivantes :

Tâches	Support
Extraction	accès aux différentes sources
Nettoyage	recherche et résolution des inconsistances dans les sources
Transformation	entre différents formats, langages, etc.
Chargement	des données dans l'entrepôt
Réplication	des sources dans l'entrepôt
Analyse	Ex : détection de valeurs non valides ou inattendues
Transfert de données haut débit	pour les très grands entrepôts
Test de qualité	Ex : pour correction et complétude
Analyse des méta données	aide à la conception

1. Les Taches de selection de donnees sources

Quelles données de production faut-il sélectionner pour alimenter l'ED?

→ **Toutes les données sources ne sont forcément pas utiles**

Ex : Doit-on prendre l'adresse complète ou séparer le code postal ?

→ **Les données sélectionnées seront réorganisées pour devenir des** informations.

§ La **synthèse** de ces données sources a pour but de les enrichir.

§ La **dénormalisation** des données crée des liens entre les données et permet des accès différents

2. Taches d'Extraction de donnees

Un extracteur (wrapper) est associé à chaque source de données :

- § Il **sélectionne** et **extraît** les données
- § Il les **formate** dans un **format cible commun**
- § Utilisation d'interfaces comme **ODB, OCI, JDBC**.
- § Le format cible est en général le **modèle Relationnel**

3. Taches de nettoyage et Transformation des données

Objectifs du nettoyage :

§ résoudre le problème de **consistance** des données au sein de chaque source

§ une centaine de type d'inconsistances ont été répertoriées

§ 5 à 30 % des données des BD commerciales sont erronées

Types d'inconsistances :

§ présence de données fausses dès leur saisie :

§ fautes de frappe

§ différents formats dans une même colonne

§ texte masquant de l'information (e.g., "N/A")

§ valeur nulle

§ incompatibilité entre la valeur et la description de la colonne

§ duplication d'information, ...

§ persistance de données obsolètes

§ confrontation de données sémantiquement équivalentes mais syntaxiquement différentes

3.1 Taches de nettoyage des données

§ fonctions de **normalisation**

§ fonctions de **conversion**


§ usage de **dictionnaires** de synonymes ou d'abréviations

Définition de table de règles :

valeur source	remplacé par	Valeur cible
Mr		M
monsieur		M
Masculin		M
M		M
Msieur		M

3.1 Taches de nettoyage des données

• Exemple de conversions



3.2 Transformation des données

Objectifs :

Suppression des incohérences sémantiques entre les sources pouvant survenir lors de l'intégration des schémas :

§ *problème de modélisation* : différents modèles de données sont utilisés

§ *problèmes de terminologie* : un objet est désigné par 2 noms différents, un même nom désigne 2 objets différents

§ *incompatibilités de contraintes* : 2 concepts équivalents ont des contraintes incompatibles

§ *conflit sémantique* : choix de différents niveaux d'abstraction pour un même concept

§ *conflits de structures* : choix de différentes propriétés pour un même concept

§ *conflits de représentation* : 2 représentations différentes choisies pour les mêmes propriétés d'un même objet des **données** :

§ *Equivalence de champs*

§ *Equivalence d'enregistrements* : fusion d'enregistrements

4. Taches de Chargement des données

Objectif :

charger les données nettoyées et préparées dans l'ED

C'est une opération :

- § qui risque d'être **assez longue**

- § plutôt **mécanique** et la **moins complexe**.

Il est nécessaire de définir et mettre en place :

- § des **stratégies pour assurer de bonnes conditions à sa réalisation**

- § une **politique de rafraîchissement**.