

IV. Exploitation d'un Entrepot de donnees (ED)

§ **OLAP, OLAP versus OLTP**

§ **Les opérations élémentaires de l'OLAP et langages pour l'OLAP**

§ **Réalisation de rapports divers (*Reporting*)**

§ **Réalisation de tableaux de bords à partir d'un ED (*Dashboards*)**

§ **Visualisations autour d'un ED (*visualizations*)**

OLAP (Online Analytical Processing)

§ Apparue dans les **années 90** dans les entreprises

§ **Façon la plus naturelle d'exploiter un ED** du fait de son organisation multidimensionnelle - cube

§ Permettent de **réaliser des synthèses, des analyses** et de la **consolidation dynamique de données multidimensionnelles organisé en cubes**

OLAP (Online Analytical Processing)

Exemple d'analyse OLAP : un supermarché ANALYSANT l'ensemble de ses ventes

§ 3 types d'opérations OLAP élémentaires liées à des transformations du cube :

§ **Restructuration** : permet un changement de points de vue selon différentes dimensions : opérations liées à la structure, manipulation et visualisation du cube : **Rotate/pivot, Switch, Split, nest, push, pull**

§ **Granularité** : concerne un changement de niveau de détail : opérations liées au niveau de granularité des données : **roll-up, drill-down**


§ **Ensembliste** : concerne l'extraction et l'OLTP classique : **slice, dice, selection, projection, jointure (drill-across)**

OLTP versus OLAP

	Caractéristiques	OLTP	OLAP
Conception	<i>Orientation</i> <i>Conception</i>	Transaction Entité-Relation	Analyse Star/snowflake
Données	<i>Granularité</i> <i>Nature</i> <i>Actualisation</i> <i>Taille fichiers</i>	Détail Relationnelle Actualisées, mises à jour < 100 Mo/Go	Résumées, agrégées Multidimensionnelle Historisées, recalculées > 100 Go/To
Traitements	<i>Unité de travail</i> <i>Accès</i> <i>Nb de tuples accédés</i> <i>Métrique</i>	Transaction simple Lecture/écriture Dizaines Débit de transactions	Requête complexe Lecture Millions Temps de réponse
Utilisateurs	<i>Utilisateur</i> <i>Nombre d'utilisateurs</i>	Agent opérationnel Milliers	Analyste/décideur Centaines

Exemple d'operations OLAP de restructuration: **Rotate/Pivot**

Rotate/pivot : effectue au cube une rotation autour d'un de ses 3 axes passant par le centre de 2 faces opposées, de façon à présenter un ensemble de faces différent (sélection de faces)



Langages pour OLAP

§ 2 langages possibles pour faire de l'OLAP :

1. SQL étendu (Extensions de SQL-3 / SQL-99 pour OLAP) :

- Nouvelles fonctions SQL d'agrégation: *Rank, N_tile, ...*
- Nouvelles fonctions de la clause GROUP BY :

§ROLLUP equivalent to “control breaks”

§CUBE equivalent to “cross tabulation”

§GROUPING SETS equivalent to multiple GROUP BYs

- Fenêtre glissante : *WINDOWS/OVER/PARTITION, ...*

2. MDX (Multi Dimensional eXpression) :

- **langage de requêtes inventé pour faire de l'OLAP** par Mosha Pasumansky (Microsoft)

- disponible dans la plupart des serveurs OLAP
- plus puissant que SQL pour faire de l'OLAP

Exemple de Requete OLAP en DMX:

SELECT {Paris, Berlin} **ON ROWS**

{[Q1], [Q2].CHILDREN} **ON COLUMNS**

FROM CubeSales

WHERE (MEASURES.SalesAmount, Time.[2014], Product.Product)

SELECT {Paris, Berlin} **ON ROWS**

{[Q1], [Q2].CHILDREN} **ON COLUMNS**

FROM CubeSales

WHERE (MEASURES.SalesAmount,
Time.[2014],
Product.Product)

Agrégation de la mesure
« SalesAmount » avec la
fonction SUM function

Sélection de la dimension
Time (2014 seulement)

Sélection de la dimension
Product (all product)

Résultat :

	Q1 2014	April 2014	May 2014	June 2014
Paris	12,567	3,360	5,450	4,570
Berlin	12,567	3,360	5,450	4,570
...	...	...	SalesAmount-values	...

OLAP et Reporting

§ Pour des utilisateurs qui ont besoin d'un **accès régulier à des informations d'une manière presque statique**

Ex: les hôpitaux doivent envoyer des rapports mensuels à des agences nationales

§ Un rapport est défini par une requête (plusieurs requêtes) et une mise en page (diagrammes, histogrammes, etc)

§ Les rapports peuvent être exécutés automatiquement ou manuellement

OLAP et Reporting

2009			BUDGET 2010			
PROIEZ.	SCOST.	MATURATO	BUDGET	PESO	Limite inferiore	Limite superiore
270	-8,8%	0%	270			
0	-100,0%	0%	0			
993	5,8%	0%	993			
6		0%	1.168			
1.168	19,0%	0%	6			
44.039	-6,3%	0%	44.039			
559	1,9%	0%	559			
2.502		0%	2.502			
2.340	6,3%	0%	2.340			
102	-40,4%	0%	102			
8,67		0%	8,67	40%		5,67
0,38		0%	0,38	30%		0,38
501.299	21,7%	0%	501.299			
0		0%	0			
3.284	-11,9%	0%	3.284			
6.524	70,3%	0%	6.524			
511.107	21,9%	0%	511.107			
1.029.189						
6,26	-10,6%	0%	6,44			
6,44						
54,26%		0%	54,26%			
3,60		0%	3,60			
70,73%		0%	70,73%			
6,40%		0%	6,40%	30%		6,40%
0,89		0%	0,89			
133.248		0%				
954.940		0%				
24.448		0%				
21		0%				
999		0%				
		0%				

Totale consumi		494.411	419.351	0%	0	0
costi personale (non da pianificare)		30.06	994.634			
unità personale		30.09	5,75	7,00	0%	0,00
presenza media		31.08	6,16			
Tasso utilizzo letti		31.08	54,10%	51,31%	0%	0,00%
degenza media		31.08	3,33	3,16	0%	0,00
tasso op		30.06	70,76%	87,23%	0%	0,00%
% ricoveri di 1 giorno		31.08	7,64%	2,00%	50%	0,00%
peso medio drg		30.06	0,68	0,61		
mobilità provinciale passiva		30.06	151.398	0	0%	0
mobilità provinciale attiva		30.06	680.010	0		
mobilità Innsbruck		30.06	30.775	0		
servizio trasporti: n° pazienti		31.08	32	0	0%	0
servizio trasporti: €		31.08	1.566	0		
Summe Gewichtung				100%		

IV. Exploitation d'un Entrepot de donnees (ED)

§ **OLAP, OLAP versus OLTP**

§ **Les opérations élémentaires de l'OLAP et langages pour l'OLAP**

§ **Réalisation de rapports divers (*Reporting*)**

§ **Réalisation de tableaux de bords à partir d'un ED (*Dashboards*)**

§ **Visualisations autour d'un ED (*visualizations*)**

OLAP et Tableaux de boards (Dashboards)

§ Affichent une quantité limitée d'informations dans un format graphique facile à lire

§ Fréquemment utilisé par les cadres supérieurs qui ont besoin d'un rapide aperçu des changements les plus importants

Ex : un aperçu en temps réel d'évolutions


§ Pas vraiment utile pour une analyse complexe et détaillée

OLAP et Tableaux de boards (Dashboards)



OLAP et Visualization de donnees

- Facilitent l'**analyse** et l'**interprétation de données**
- convertissent des données complexes en **images**, **graphiques en 2 et 3 dimensions**, voire en **animations**
- Sont de plus en plus **intégrées dans les ED**



V. Domaines d'application et Exemples d'Entrepôts de données

§ Domaine bancaire

§ Domaine de la grande distribution

§ Domaine des télécommunications

§ Domaines de l'assurance et de la pharmacie

§ Domaine de la santé, ...

Domaine bancaire: un des premiers utilisateurs des ED

§ Pour une banque, il est important de pouvoir **regrouper les informations relatives à un client** afin de répondre à ses demandes de crédit par exemple

§ **Des mailing ciblés doivent aussi être rapidement élaborés** à partir de toutes les informations disponibles sur un client lors de la commercialisation d'un nouveau produit

§ **L'utilisation de cartes de crédit nécessite des contrôles à posteriori**, par exemple pour la recherche de fraudes : la mémorisation des mouvements peut rendre de grands services

§ **Les échanges d'actions et de conseils de courtages sont facilités** par une mémorisation de l'histoire et une exploitation par des outils décisionnels avancés par exemple pour déterminer des tendances de marchés

Domaine de la grande distribution: fortement demandeur d'ED

§ Intéressant de **regrouper les informations de ventes** pour déterminer les **produits à succès**, mieux suivre les **modes**, détecter les **habitudes d'achats**, les **préférences des clients** par secteur géographique

§ La **fouille de données** (Data Mining) a permis de développer des techniques sophistiquées d'exploitation de données qui aident à **mettre en évidence les règles** de consommation

§ **Explorer le panier de la ménagère** est devenu un exercice d'école : il s'agit de trouver à partir de l'enregistrement des transactions quelles sont les habitudes d'achats, plus précisément quels sont les produits achetés en même temps

Apports constatés dans la grande distribution :

§ **augmentation des ventes grâce à un meilleur marketing**

§ **amélioration des taux de rotation de stocks**

§ **élimination des produits obsolètes**

§ **réduction des rabais, remises, ristournes**

§ **meilleure négociation des achats**

Domaine tres concurrentiel des Telecommunications: utilise beaucoup les ED

§ **Grande masse de données** concernant les abonnés et les appels est **enregistrée**

§ **Plusieurs mois de description détaillée des appels** comprenant, pour chaque appel appelant, appelé, heure et durée sont disponibles chez les opérateurs

En respectant les lois de sécurité et liberté, que peut-on faire de telles données ?

Couplées ou non avec des informations comptables, l'exploitation de ces données regroupées en ED par des techniques d'analyse et d'exploration permet :

§ **D'analyser le trafic,**

§ **De mieux cerner les besoins des clients,**

§ **De classer les clients par catégories,**

§ **De comprendre pourquoi certains changent d'opérateurs** et mieux répondre à leurs besoins

Domaine de l'assurance et de la pharmacie: tres friands de techniques décisionnelles

§ L'exercice de base de l'assureur est de **déterminer le facteur de risque** d'un assuré

§ Celui d'un **producteur pharmaceutique** est de **détecter l'impact** d'un médicament

§ Plus généralement, le **suivi des informations relatives à la liaison produit-client** sur un ED est souvent synonyme de **gains importants** : meilleure connaissance des produits, détection des défauts, meilleure connaissance des clients, détection de rejets, ciblage du marketing, etc

§ Le couplage aux **technologies du Web** ouvre aussi des horizons nouveaux pour le suivi des produits, des clients, des concurrents : notion émergente de « **Data Webhouse** »

Exemple dans la grande distribution (1)

Exemple du groupe Casino :

Projet :

§ un des premiers entrepôts en France

§ plusieurs millions de dollars économisés en s'apercevant que les stocks de coca-cola faisaient souvent défaut...

§ 1994 : 80 Go et 50 utilisateurs

§ 2002 : + de 10 To, 1500 utilisateurs, 25000 requêtes/jour

Solution : Teradata

Exemple dans la grande distribution (1)

Exemple du groupe Walmart :

Projet :

§ le plus gros entrepôt de données du monde, en 2006 : 0.5 Po de données

§ distributeurs, magasins, clients ($> 10^8$), produits ($> 10^9$)...

§ un des plus secret également...

Solution : Teradata

Wal-Mart, for example, discovered that people who buy Pampers often buy beer, so they moved Pampers and beer close together. The result was that sales of both increased (Computer Business Review, October 1996)

Exemple dans la grande distribution (2)

Exemple du groupe Camaieu:

Projet :

§ plusieurs systèmes de production (magasin, logistique, comptable, etc.)

Solution :

§ 1996 : agrégés dans un entrepôt de données, via l'ETL Sunopsis

§ base Oracle découpée en référentiels métier (datamarts achat, marketing...)

§ consultation des datamarts via le système de reporting de Business Objects

§ 2003 : ajout d'un cube OLAP intégré à la base relationnelle Oracle9i :

§ meilleure ergonomie,

§ permet des requêtes complexes avec prise en compte de plusieurs niveaux au sein de la BD (types d'articles, collections, produits, zones géographiques, ...)

§ base de composants Java (BI Beans) livrée par l'éditeur au sein de son environnement de développement (Jdeveloper).

Exemple dans les Telecommunications

Exemple de France Télécom :

Le projet :

- § 12 BD sources

- § récupération des données : 1,5 année

- § données régionales et nationales

- § parfois chez des prestataires de services

- § parfois au prix d'un intense lobbying

- § en 2003 : environ 5 années de travail

Exemple dans les Télécommunications

Solution :

§ entreposage : SQL server

§ DW de 3 bimestres, vidé périodiquement

§ 1,2 million d'individus

§ 1 fait = 1 client

§ 250 colonnes

§ intégration faite à la main périodiquement

Exploitation : progiciel de DM développé spécifiquement