

18-08-2023

TD N° 1

Exo 1 :

- a) Décrivez le schéma en étoile que l'on retrouve dans les entrepôts de données. Précisez le rôle des différents types de tables dans un tel schéma.
- b) Expliquez la différence entre les clauses CUBE et ROLLUP.
- c) Identifiez un groupe d'attributs formant une hiérarchie dimensionnelle dans la table de dimension suivante :

Produit
idProduit (PK)
description
SKU
marque
sousCatégorie
catégorie
département
poids
taille
couleur
...

Figure 1 : Table VENTE

Comment serait modélisée cette hiérarchie dans un schéma normalisé ?

- c) À quoi sert la pré-agrégation des faits et comment peut-on implémenter cette stratégie dans le contexte des BD relationnelles ?
- d) Illustrez à l'aide d'un exemple chacune des opérations OLAP suivantes : slice, rotate, roll-up, et drill-down.
- e) Quelle est la différence entre les approches ROLAP et MOLAP pour la gestion de données dimensionnelles ?

Exo 2:

Considérez le schéma suivant:

- Film(idFilm, titre, annee, description);
- Personne(idPersonne, nom, dateNaissance, bio);
- RoleFilm(idFilm, idPersonne, personnage);
- GenreFilm(idFilm, genre);

a) Écrivez une requête SQL utilisant les fonctions analytiques d'Oracle permettant d'afficher, pour chaque genre et chaque année, le nombre de films produits depuis cette année ayant ce genre.

b) Quelle est la différence entre les résultats obtenus par les deux requêtes suivantes?

Requête 1

```
SELECT F.idFilm, COUNT(*) as col FROM Film F, GenreFilm GF WHERE F.idFilm = GF.idFilm  
GROUP BY F.idFilm
```

Requête 2

```
SELECT F.idFilm, COUNT(*) OVER ( PARTITION BY F.idFilm) as col FROM Film F, Genre G  
WHERE F.idFilm = G.idFilm
```

Exo 3:

Une agence de voyage aimerait pouvoir analyser ses données afin de planifier de meilleures campagnes de promotion auprès de ses clients. Plus particulièrement, elle aimerait analyser le nombre et le montant des ventes en fonction :

- De la destination: hôtel, ville, pays, région, catégorie de région (ex: bord de mer, alpine, etc.), catégorie de destination (ex: familial ou non), catégorie hôtel (ex: 1-4 étoiles) ;
- De la date d'achat: jour de l'année, jour de la semaine, mois, année, saison touristique (ex: basse ou haute saison);
- De la date de départ: jour de l'année, jour de la semaine, mois, année, saison touristique (ex: basse ou haute saison);
- Du forfait: nombre de personnes, nombre de nuits, type de forfait (ex: tout inclus, repas inclus, etc.), type de chambre (ex: standard, suite, penthouse, etc.) ;
- Du client: groupe d'âge, sexe, adresse, type d'acheteur (ex: nouveau, récurrent, etc.) ;
- Du canal de vente: catégorie (ex: magasin, internet, etc.) ;
- De la promotion: catégorie (ex: 2 pour 1, rabais 10%, rabais 25%, etc.), début et fin de validité ;
- Du mode de paiement: catégorie (ex: crédit, comptant, etc.) ;

- a) Proposez un schéma en étoile permettant de faire ces analyses. Identifiez clairement les clés primaires et étrangères des tables de faits et de dimension;
- b) Identifiez, pour chaque table de dimension, une hiérarchie de niveaux de granularité (e.g., attribut1 ← attribut2 ← ...);
- c) Proposez une stratégie d'agrégation ajoutant une nouvelle table de faits agrégés.

Donnez le code SQL permettant de créer cette nouvelle table.

Exo 4 :

TU Hôtels est une petite chaîne d'hôtels ayant des propriétés dans plusieurs états américains. L'entreprise possède une base de données centralisée pour stocker et faire le suivi des réservations de ses clients. En 2008, ils ont installé des restaurants appelés Café in the Hotel dans plusieurs de leurs hôtels. Un système est employé pour faire le suivi des commandes et les relayer aux employés dans les cuisines.

TU Hôtels aimerait utiliser les données qu'ils ont emmagasinées pour mieux comprendre la performance de leurs hôtels et restaurants. Ils ont également accès à une base de données de critiques de clients provenant du site web HotelComplainer.com.

La tâche est de faire la conception de deux magasins de données (data marts) utilisant les données provenant des trois sources mentionnées ci-haut. Vous devrez faire un schéma en étoile pour chaque magasin de données en choisissant les dimensions, les faits, et les attributs à partir des sources, dont le schéma est fourni ci-dessous.

La table suivante présente les questions analytiques auxquelles devra répondre vos magasins de données :

Data mart 1: Performance des hôtels

- Durant quel mois y a-t-il le plus grand nombre de réservations de chambre?
- Quelle est la saison morte pour les hôtels situés dans une région particulière?
- Quels hôtels génèrent le plus de revenus (non attribuables aux restaurants)?
- Quel est la durée moyenne des

Data mart 2: Performance des restaurants

- Quels restaurants génèrent le plus de revenus?
- Les restaurants les mieux cotés génèrent-ils plus de revenus?
- Quel est l'item commandé le plus souvent dans une région particulière?

Pour compléter l'exercice, vous devrez suivre les étapes suivantes :

- 1) Identifiez le principal événement d'affaires pour chaque magasin de données;

Posez-vous la question suivante : "Quel est l'évènement d'affaires qui génère la (les) métrique(s) de performance?"

- 2) Identifiez les attributs associés aux faits.


Posez-vous la question suivante : “Comment l’évènement d’affaires est-il mesuré?”

3) Identifiez les dimensions et leurs attributs.


Posez-vous la question suivante : “Quelles données caractérisent les différents aspects de l’évènement d’affaires?”

4) Élaborez le schéma en étoile selon les principes vus en classe.

Hotel Reservation Database



HotelComplainer Ratings Database
(totally external company)



Café in the Hotel Database (same company but
database is not connected to the hotel)

